

TE-KG：具备来源追溯能力的 人类转座元件知识图谱与多层次资源

作者姓名待补充

院系、单位及通讯作者信息待补充

中文审阅稿 v0.1, 2026 年 8 月 1 日

本中文稿仅供内容审阅，不作为投稿源文件；如有歧义，以英文稿为准。

摘要

人类转座元件的相关证据分散在重复序列分类、参考序列、基因组注释、表达数据集和生物医学文献之中。这些来源回答的问题各不相同；若在整合时忽略其证据单位的差异，就难以进行可靠的联合分析。我们构建了 TE-KG，这是一个面向人类转座元件的资源，将文献提取的生物医学关系、分类体系、代表性序列和基因组记录、表达谱以及特定生物学情境下的共表达网络连接起来。在本文所述的运行时快照中，知识图谱包含 225 个转座元件节点、2,308 个论文节点和 12,444 条有向生物学关系。每条生物学关系均保留谓词和 PubMed 来源信息。表达数据包括正常组织、正常原代细胞和癌细胞系三类情境，共 1,158 个样本；共表达目录为 285 个转座元件和 499 个基因提供了经审核、可检索的网络。该网络资源支持浏览、知识图谱与路径探索、表达查看、数据下载以及受证据边界约束的自然语言问答。TE-KG 的设计目标是连接互补证据，而不是抹平证据差异：文献关系不被解释为因果关系，共识序列不被视为特定拷贝序列，共表达边也只表示相关性而非调控关系。该结构在保留各来源证据边界的同时，为从转座元件身份出发检索多种生物学证据提供了可追溯路径。

关键词：转座元件；知识图谱；生物医学文献；表达；共表达；数据库

缩写：TE, 转座元件；FDR, 错误发现率；PMID, PubMed 标识符；RMSK, 来源于 RepeatMasker 的注释

数据库网址：[\[待补说明：投稿前必须提供稳定、公开且无需登录的正式网址。\]](#)

1 引言

转座元件（transposable element, TE）是人类基因组的重要组成部分，研究者通常通过几类相互补充的表示方式研究它们。重复序列家族资源描述分类体系和共识序列模型，基因组注释记录单个或代表性位点，表达数据集测量特定样本中的转录水平，而生物医学文献则报道 TE 与基因、疾病及其他实体之间的关联。这些表示方式不能相互替代。家族共识序列并不等同于每个基因组拷贝的序列，观察到某个基因组位点并不能证明其具有活性，文献报道的关联本身也不能建立因果关系。因此，对 TE 证据的解释同时取决于证据来源和观察单位。

现有专业资源在特定证据类型上具有较大深度。Repbase 和 Dfam 支持重复序列家族分类与参考序列模型 (1, 6, 16)。HERVd、dbRIP、euL1db 和 TranspoGene 分别整理内源性逆转录病毒序列、逆转录转座子插入多态性、样本特异性 L1HS 插入或基因环境注释 (8, 11, 12, 15)。较新的资源进一步关注疾病或表达证据。HervD Atlas 整理 HERV 与疾病的关联并通过交互式知识图谱提供访问, CancerHERVdb 聚焦癌症中的 HERV 表达, TE-SCALE 则提供人类癌症单细胞水平的 TE 表达和 TE-基因共表达信息 (9, 10, 13)。这些专业资源能够以较高分辨率回答重要问题, 通用整合资源不应声称能够取代它们。

尚未充分解决的实际问题是跨证据层导航。研究者从一个 TE 名称出发, 可能需要确定其分类、查看参考序列或基因组记录、比较不同表达情境、识别相关基因, 并打支持某条疾病或基因关系的论文。当这些步骤分散在不同资源中时, 名称和证据边界需要反复对齐。相反, 如果把异质记录合并到一个不加区分的图中, 较弱或间接的证据又可能显得比实际更强。因此, 有价值的整合不仅要连接记录, 还必须保留其来源和解释限制。

本文介绍 TE-KG, 一个以人类 TE 为中心的资源, 用于连接文献提取的生物学关系、分类体系、代表性基因组与序列记录、表达谱以及特定情境下的共表达网络。TE-KG 通过图、路径、表格、可视化、下载和自然语言等入口访问这些证据层。其核心设计原则是: 整合应当使不同证据能够被联合访问, 但不能抹去各来源能够支持的结论边界。本文报告当前数据库内容、数据处理与运行时架构以及主要科学访问流程, 并明确限制生物学解释的因素和公开发布前仍需补充的信息。

2 材料与方法

2.1 范围与证据模型

TE-KG 以人类 TE 为共享标识符, 连接原本彼此独立的证据层。文献层保存从论文中提取的生物学实体和关系; 分类层表示 TE 记录之间的分类关系; 序列和基因组记录提供来自不同上游来源的参考性或代表性信息; 表达矩阵保存样本情境下的测量值; 共表达网络则概括 TE 与基因特征在特定情境中的秩相关。系统并未为这些证据层赋予相同的证据含义, 而是由各运行时入口标明来源类型, 并限制描述结果时可以使用的语言。

2.2 文献收集、信息提取与标准化

项目使用已记录的 TE 名称、别名和 TE 相关术语组合检索 PubMed 中的人类 TE 文献。归档流程覆盖截至 2026 年 4 月 13 日可获得的论文。候选记录根据 TE 白名单筛选并在纳入前进行标准化。最终保留的语料库包含 2,308 篇论文, 与当前 Neo4j 数据库快照中的 Paper 节点数一致。

保留的文本和元数据通过带约束的 DeepSeek-V3 提示词处理, 用于识别以 TE 为中心的生物学陈述及其参与实体。提取实体被映射到 11 类生物学实体: 碳水化合物、疾病、功能、基因、脂质、突变、肽、药物、蛋白质、RNA 和毒素。每条关系记录保留标准化谓词、一个或多个支持该关系的 PubMed 标识符 (PMID), 以及支持 PMID 的数量。自动标准化包括使用 80% 的 Ratcliff-Obershelp 相似度阈值进行名称匹配; 当自动解析不足时, 再进行人工映射。图导入

前还通过人工整理审核保留的实体和关系。

归档方法记录记载了三轮人工审核，每轮包含 50 条记录。本文草稿不将这些百分比作为定量性能结论，因为目前尚未一致恢复抽样标识符、抽样种子、准确分母和中间筛选计算。[待补说明：锁定本小节前，需恢复文献检索式、准确的 DeepSeek-V3 端点或模型版本、中间记录数以及抽样审核决定。]

2.3 TE 分类、序列与基因组记录

TE 身份和分类记录来自一个 RepBase 衍生的本地来源，基因组位置则来自 RepeatMasker 衍生的 RMSK 注释来源。Repbases 是重复序列家族和共识序列的经典参考资源 (1, 6)；Dfam 提供互补的家族模型框架 (16)。TE-KG 保留这些来源角色之间的区别。RepBase 衍生序列被描述为共识序列或参考序列，RMSK 衍生位置被描述为代表性基因组记录。两者都不被表述为活跃、具有多态性或样本特异性插入的完整清单。

分类体系由 Neo4j 支持的 API 提供，而不是使用第二套浏览器端事实来源。分类边使用明确的图关系 CLASSIFIED_AS、SUBFAMILY_OF 和 HAS_SUBCATEGORY。分类 API 可以提供所有受支持 TE 记录的当前树，也可以提供网页界面使用的 RMSK 加 RepBase 视图。[待补说明：补充准确的 RepeatMasker 版本或构建、RepBase 版本、获取日期以及许可和再分发条款。]

2.4 表达数据集与情境定义

表达层包含三个当前使用的矩阵。正常组织矩阵含 37,868 个特征和 205 个样本；正常原代细胞矩阵含 37,868 个特征和 307 个样本；癌细胞系矩阵含 37,868 个特征和 646 个样本。三个矩阵共计 1,158 个样本。特征标识符同时包括 TE 或重复序列特征和基因，因此这些矩阵不会被描述为仅包含基因的表达数据。

正常组织数据与 E-MTAB-1733 和 E-MTAB-2836 研究相关 (4, 14)。癌细胞系数据与 PR-JNA523380 和 Cancer Cell Line Encyclopedia 相关 (5)。当前正常原代细胞矩阵与 SRP013565 相关；该 ENCODE RNA-seq 研究包含异质性较高的实验。[待补说明：冻结三个矩阵的“登录号到本地样本”对应清单，并确定 SRP013565 的准确子集及主要引用。]

元数据审核发现，正常组织元数据中存在重复的运行标识符，并且有五个矩阵运行记录无法在元数据中匹配：ERR579126、ERR579137、ERR579144、ERR579145 和 ERR579154。这些问题仍作为限制保留，必须在公开发布清单中解决或明确排除。运行时键 `normal_cell_line` 实际指正常原代细胞情境；论文中使用“正常原代细胞”，以避免与转化细胞系混淆。

2.5 特定情境下的共表达网络

共表达分别在正常组织、正常原代细胞和癌细胞系情境中计算。丰度值按 $\log_2(\text{count} + 1)$ 转换，TE-基因关联使用 Spearman 秩相关衡量。候选边在 $|r| \geq 0.4$ 且 Benjamini-Hochberg 错误发现率 (FDR) 不高于 0.05 时保留 (2)。保留的正相关边用于 Louvain 社区发现，随机种子为 42，分辨率为 1.8 (3)。系统将这些边解释为统计相关，而不是 TE 调控基因的证据。

完整离线网络输出作为来源记录和导入输入保留。正式界面提供从这些结果中筛选并经批准

的、由 MySQL 支持的展示网络。当前展示约定将单次返回的网络限制为最多 50 个节点和 150 条边，以便保持交互响应，同时避免将所展示子图描述为完整相关网络。本文报告的目录版本为 v1_abs0.4_fdr0.05_res1.8。

2.6 图数据库、关系型存储与网页应用

正式知识图谱存储在 Neo4j 数据库 `tekg3` 中。MySQL 存储版本化的 Browse 目录、表达数据和经批准的共表达数据集。PHP API 负责访问两种数据库系统，浏览器端 JavaScript 则负责渲染表格、图表、分类视图以及交互式 G6 或 Canvas 图。该架构避免把大型表达矩阵和展示网络记录强行放入文献图谱，同时保留统一的 TE 中心化界面。

知识图谱界面支持实体搜索、关系筛选、交互式节点扩展、关系图例和 PMID 证据链接。Path 界面用于搜索所选实体之间的连接。Browse、分类体系和 Expression 提供 TE 身份与定量表达谱的结构化访问，Download 则提供可复用的图、分类和表达文件。论文中所有界面相关计数均来自带日期的只读数据库查询或实时 API 响应，而不是直接抄录界面标签。

2.7 受证据边界约束的自然语言检索

Agent 和 DeepThink 提供两种访问本地资源的自然语言模式。二者使用包含 12 类证据检索角色的目录，覆盖实体解析、图、路径、序列、分类、基因组、表达、共表达和文献任务。语言模型根据问题选择证据，服务器则执行路由限制、证据充分性检查和受限回退。回答可以包含 PubMed 链接，也可以使用当前浏览器对话中的前文。对话上下文不会在刷新页面、打开新标签页或启动新会话后保留。

智能界面被视为访问层，而不是主要科学结果。内部路由标签、插件名称和开发诊断信息会从面向用户的文字中移除。因此，本文仅报告已实现的行为与测试覆盖，不给出单一的总体准确率。已知的局部限制仍明确披露，包括部分情况下只能进行标题层级的文献检索，以及带疾病限定条件的检索仍可能不完整。

2.8 验证与快照策略

数据库计数于 2026 年 7 月 31 日通过只读 Neo4j 查询、实时 PHP API 和仓库检查进行验证。每条生物学关系按其存储方向计数一次。另一种无向遍历计数会将每条已存储的有向关系计算两次，因此未被采用。API 契约、运行时数据库配置、图渲染、分类事实来源、共表达目录一致性以及 Agent/DeepThink 行为均通过仓库中的自动化与浏览器回归脚本检查。与环境相关的响应时间未被用作生物学或性能结论。

3 结果

3.1 具有明确来源信息的文献关联人类 TE 图谱

当前 Neo4j 快照包含 225 个 TE 节点和 2,308 个 Paper 节点，同时包含 12,444 条连接 TE 与生物医学实体的有向 `BIO_RELATION` 关系。当前每条生物学关系均具有标准化谓词、至少一个

PMID 字段和支持 PMID 计数。这些属性使界面中的边可以追溯到用于支持该关系的文献记录，但可追溯性并不会把提取出的关联转化为因果证据。

生物医学模式包含 11 类实体。目前数量较多的标签包括 Function（3,683 个节点）、Gene（1,280）、Protein（1,089）、Disease（676）、RNA（588）、Mutation（377）和 Pharmaceutical（293）。数量较少的类别包括 Toxin（67）、Lipid（26）、Peptide（23）和 Carbohydrate（12）。DiseaseCategory（767）、Paper（2,308）及分类相关节点单独表示，因为它们承担组织或来源追踪作用，而不属于上述 11 类生物医学实体。

表 1: 当前 TE-KG 内容快照。各项计数代表不同的运行时单位，不得相加。快照于 2026 年 7 月 31 日完成验证。

组成部分及单位	数量	定义	来源与边界
Neo4j TE 节点	225	tekg3 图中的 TE 实体	实时标签计数查询；与 Browse 条目不是同一单位
Neo4j Paper 节点	2,308	图中表示的保留论文	实时标签计数查询；与最终文献语料库一致
有向生物学关系	12,444	已存储的 BIO_RELATION 关系	按存储方向计数一次；当前全部记录均含谓词和 PMID 来源字段
生物医学实体类别	11	碳水化合物、疾病、功能、基因、脂质、突变、肽、药物、蛋白质、RNA 和毒素	不包括 Paper、DiseaseCategory 和分类标签
Browse 目录条目	276	版本化 TE 目录记录	由 MySQL 支持的 Browse API；与图 TE 节点属于不同记录单位
已分类 TE	225 个中的 192 个	实时摘要中已具有分类类别的 TE 节点	由 Neo4j 支持的分类型 API
表达样本	1,158	205 个正常组织、307 个正常原代细胞和 646 个癌细胞系样本	三类来源组；不是跨情境配对队列
可检索共表达条目	784	285 个 TE 和 499 个基因条目	三类情境的经批准展示目录；不是完整离线网络的特征数量
下载文件	10	6 个表达文件、2 个图文件和 2 个分类文件	当前网页入口；仍需公开归档发布

3.2 分类视图与目录视图保留不同的记录单位

实时分类摘要包含 225 个 TE，其中 192 个已分配分类类别。摘要还报告 188 个标准叶节点，并将包含 36 条记录的全来源树与包含 189 条记录 RMSK 加 RepBase 树分开。这些数值描述的是 API 定义的分类视图，而不是彼此独立的生物学总数。Browse 目录包含 276 条版本化

记录。由于 Browse 与 Neo4j TE 节点代表不同的记录单位，该较大的 Browse 数量单独报告，不能与图中的 TE 节点数合并为一个 TE 总数。

分类界面在使用同一套 API 分类数据的前提下，同时提供层级树和力导向图。图例可以暂时隐藏或恢复 TE 类别，而不会改变底层结果集。这种交互有助于查看密集分类，但不会引入第二个分类事实来源，也不会修改分类归属。

3.3 表达与共表达增加三类生物学情境

当前表达矩阵包含 205 个正常组织样本、307 个正常原代细胞样本和 646 个癌细胞系样本。共计 1,158 个样本，为 TE 和基因表达查看提供三类情境。由于这些情境来自不同研究和采样设计，系统将其相互分开。当前数据不支持把它们视为配对的实验比较。

正式共表达目录覆盖相同的三类情境，并包含 285 个 TE 和 499 个基因的经批准可检索条目。三个情境合计提供 849 条展示建议：17 条标记为核心案例，287 条标记为高置信条目，542 条标记为可检索条目，另有 3 条不建议默认展示。这些层级用于控制呈现和可检索性，并不代表统计显著性类别。所有展示边均已满足固定的相关系数和 FDR 阈值，单次返回的展示网络只是更大离线结果的受限视图。

3.4 相互连接的界面提供互补证据入口

TE-KG 针对不同问题提供多个访问入口。Browse 和 Search 用于解析 TE 名称并进入结构化身份记录；Knowledge Graph 展示文献关联的生物学关系并提供 PubMed 证据；Path 搜索所选实体之间的连接；Expression 展示特定情境下的丰度谱；Co-expression 展示 TE-基因相关邻域；Download 当前提供 10 个文件，包括 6 个表达文件、2 个图文件和 2 个分类文件。

这些入口在 TE 身份层面相互连接，但保留不同的证据含义。例如，打开图中的疾病关联边可以访问支持论文，而不是声称该 TE 导致疾病。同样，打开共表达邻域会报告分析情境和相关阈值，而不是调控机制。保持这种区分是面向用户的设计组成部分，而不仅是内部实现细节。

3.5 自然语言追问仅限当前会话

Agent 和 DeepThink 可以根据英文问题检索多个本地证据层，并理解当前对话中的追问。生成回答中的 PubMed 标识符会显示为指向 PubMed 的链接。写作层使用普通科学语言表达证据限制，不向用户展示内部路由、置信标签或其他开发诊断信息。例如，回答可以将一条关系描述为仍需实验验证的关联，而不要求读者理解内部状态代码。

当前评估支持功能覆盖结论，但不支持总体准确率结论。固定的 13 题基线覆盖了全部 12 类检索角色，后续回归检查在定向修复后保护了图路由、文献链接和多插件行为。更早的一次 36 题测试包含后来已经修复的失败，但整个测试集尚未作为同一版本锁定的基准重新运行。因此，本文将该界面描述为受边界约束的检索入口，并保留具体已知限制，而不把历史通过率作为当前性能发表。

3.6 跨证据层的 L1HS 使用案例

L1HS 被选为主要示例，因为它可以在当前分类、图、序列、基因组、表达和共表达界面中解析。最终图件将在每个分面中保留结果类型的区别，并将所有文献陈述连接到已核实的 PMID。
[待补说明：本小节达到论文可用状态前，需冻结准确的 L1HS 记录、表达来源表、共表达邻域，以及一到两条由 PMID 支持的图关系。不得使用通用模型知识填补缺失证据层。]

4 讨论

TE-KG 处理了人类 TE 研究中的一个实际整合问题：同一命名元件的证据分散在家族参考资源、基因组注释、表达矩阵和生物医学论文中。该资源通过共享的 TE 身份和相互连接的访问流程连接这些证据层。其主要贡献并不是单独使用图技术，而是将带 PMID 的文献图谱与分类、代表性序列和基因组记录、三类表达情境及特定情境下的共表达视图结合，同时使每个证据层的解释边界保持可见。

这种定位有意与专业资源形成互补。Rebase 和 Dfam 提供更深入的重复序列家族参考与模型 (1, 16)。dbRIP 和 euL1db 以 TE-KG 目前无法提供的分辨率描述插入多态性和样本特异性 L1HS 记录 (11, 15)。HervD Atlas 对 HERV-疾病关联进行更深入的人工整理，TE-SCALE 则以超过本文批量数据集的规模提供癌症单细胞表达和共表达信息 (9, 10)。因此，当问题跨越多种证据类型时，TE-KG 最具价值；如果用户需要某一专业领域中分辨率最高的记录，则应优先使用相应专业资源。

文献图谱具有明确的来源追踪优势，也具有明确限制。保留谓词和 PMID 使图中的边可被检查，并允许用户返回原始论文。然而，当前语料库经过自动筛选、受约束的语言模型提取、标准化和人工整理等步骤生成。检索、缩写解析、实体标准化或原文解释均可能产生错误。PMID 的存在说明关系可以追溯，并不证明关系一定正确，也不证明因果性。在提取流程能够支持定量准确率结论之前，还需要完成可复现的人工审核并保存样本标识符。

表达和共表达也需要类似的谨慎。TE 表达估计对重复序列特征和定量方法较为敏感 (7)。TE-KG 的三类情境来自不同研究，不能被解释为配对的正常与癌症实验。正常组织元数据还包含重复标识符和五个无法与矩阵匹配的运行记录。共表达分析进一步将数据简化为达到阈值的两两相关和模块。FDR 控制限制保留统计检验中预期的假发现比例，但不能建立调控关系。展示目录又增加了一层筛选，因为它提供的是受限且经批准的子图，而不是全部离线边。

智能界面降低了跨多个存储检索证据的操作成本，但其地位应低于能够直接看到来源的数据库访问。会话范围内的追问支持简短的研究对话，而无需建立持久用户画像。与此同时，回答质量取决于实体解析、插件选择、本地证据可用性和语言模型综合能力。即使底层资源包含有用记录，界面仍可能遗漏相关文献或给出不完整回答。因此，保持 PubMed 链接可见，并使用面向读者的语言表达不确定性，比展示内部推理步骤更重要。

投稿和公开发布前仍有若干要求需要满足。必须记录准确的 RepeatMasker 和 RepBase 版本、获取日期及再分发条款；必须冻结表达数据的“登录号到样本”清单，包括 SRP013565 子集和五条正常组织元数据不匹配记录；还需要稳定的公开网址、版本化代码和数据存档、许可证及更新策略。当前 Database 投稿要求资源免费、无需登录，并至少保持两年可用，因此只有本

地部署和 Download 页面并不充分。

下一步最有信息量的评估不是增加更多界面截图，而是建立可复现的跨证据层案例。锁定的 L1HS 示例可以检验用户能否从身份信息进入分类、代表性序列或位置、表达、共表达和文献证据，同时不丢失来源信息或夸大结论。再增加一个 HERV 或 DNA 转座子案例，有助于判断该流程能否推广到代表性最强的 LINE 示例之外。这些案例应把证据缺失作为结果的一部分报告，而不是使用未经核实的生成文字进行补充。

5 结论

TE-KG 为多种人类 TE 证据提供了具备来源追溯能力的访问路径。当前知识图谱以 12,444 条带 PMID 的有向生物学关系连接 225 个 TE 节点和 2,308 篇论文；独立的分类、序列、基因组、表达和共表达存储则支持互补问题。相互连接的网页和自然语言流程使这些证据层可以被联合访问，同时不赋予它们相同的证据含义。因此，该资源最适合被理解为一个整合与导航层：文献关系仍是关联，参考序列仍有别于单个基因组拷贝，共表达也仍然只是相关性。在解决剩余的来源、发布和使用案例要求后，该结构能够支持跨数据类型、可追溯的人类 TE 研究，并将用户引导回底层原始记录。

6 数据可用性

当前开发版本通过 TE-KG 网页界面提供图、分类和表达数据下载。[待补说明：使用稳定的公开数据库网址、版本化仓库与归档标识符、文件级许可证、发布版本、更新策略和“登录号到样本”清单替换本工作声明。最终资源必须免费开放，且无需登录或注册。]

7 补充数据

[待补说明：提供表格计划中所述的冻结来源表、查询文件、数据清单、文献审核记录、共表达敏感性分析输出和详细验证结果。]

8 致谢

[待补说明：需要作者提供。]

9 经费支持

[待补说明：需要作者提供，包括资助机构名称、项目编号和接受资助的作者姓名缩写。]

10 利益冲突

[待补说明：需要作者提供。]

参考文献

- [1] Weidong Bao, Kenji K. Kojima, and Oleksiy Kohany. Repbase update, a database of repetitive elements in eukaryotic genomes. *Mobile DNA*, 6(1):11, 2015.
- [2] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [3] Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008, 2008.
- [4] Per-Henrik D. Edqvist, Linn Fagerberg, Björn M. Hallström, Angelika Danielsson, Karolina Edlund, Mathias Uhlén, and Fredrik Pontén. Expression of human skin-specific genes defined by transcriptomics and antibody-based profiling. *Journal of Histochemistry and Cytochemistry*, 63(2):129–141, 2015.
- [5] Mahmoud Ghandi, Franklin W. Huang, Judit Jané-Valbuena, Gregory V. Kryukov, Christopher C. Lo, et al. Next-generation characterization of the cancer cell line encyclopedia. *Nature*, 569(7757):503–508, 2019.
- [6] Kenji K. Kojima. Human transposable elements in repbase: genomic footprints from fish to humans. *Mobile DNA*, 9(1):2, 2018.
- [7] Sophie Lanciano and Gaël Cristofari. Measuring and interpreting transposable element expression. *Nature Reviews Genetics*, 21:721–736, 2020.
- [8] Asaf Levy, Noa Sela, and Gil Ast. TranspoGene and microTranspoGene: transposed elements influence on the transcriptome of seven vertebrates and invertebrates. *Nucleic Acids Research*, 36(Database issue):D47–D52, 2008.
- [9] Cuidan Li, Qiheng Qian, Chenghao Yan, Mingming Lu, Lin Li, et al. HervD Atlas: a curated knowledgebase of associations between human endogenous retroviruses and diseases. *Nucleic Acids Research*, 52(D1):D1315–D1326, 2024.
- [10] Xini Meng, Zhi Nie, Qifei Wang, Yiwen Hu, Yulan Deng, et al. TE-SCALE: a comprehensive database for exploring transposable element expression across human cancers at single-cell resolution. *Nucleic Acids Research*, 54(D1):D1658–D1671, 2026.
- [11] Ashfaq A. Mir, Claude Philippe, and Gaël Cristofari. euL1db: the european database of L1HS retrotransposon insertions in humans. *Nucleic Acids Research*, 43(D1):D43–D47, 2015.
- [12] Jan Pačes, Adam Pavlíček, and Václav Pačes. HERVd: database of human endogenous retroviruses. *Nucleic Acids Research*, 30(1):205–206, 2002.

- [13] Erik Stricker, Erin C. Peckham-Gregory, and Michael E. Scheurer. CancerHERVdb: Human endogenous retrovirus (HERV) expression database for human cancer accelerates studies of the retrovirome and predictions for HERV-based therapies. *Journal of Virology*, 97(6):e00059–23, 2023.
- [14] Mathias Uhlén, Linn Fagerberg, Björn M. Hallström, Cecilia Lindskog, Per Oksvold, et al. Tissue-based map of the human proteome. *Science*, 347(6220):1260419, 2015.
- [15] Jianxin Wang, Lei Song, Deepak Grover, Sami Azrak, Mark A. Batzer, and Ping Liang. dbRIP: a highly integrated database of retrotransposon insertion polymorphisms in humans. *Human Mutation*, 27(4):323–329, 2006.
- [16] Travis J. Wheeler, Jody Clements, Sean R. Eddy, Robert Hubley, Thomas A. Jones, Jerzy Jurka, Arian F. A. Smit, and Robert D. Finn. Dfam: a database of repetitive dna based on profile hidden markov models. *Nucleic Acids Research*, 41(D1):D70–D82, 2013.