

TE-KG 智能体系统架构与修复说明

TE-KG Project

2026 年 5 月 7 日

1 文档目的

本文档记录 TE-KG 当前智能体系统的运行方式，以及本轮针对明显稳定性问题实施的修复。范围仅包括 Deep Think、Agent、插件执行、LLM 调用、异步运行编排和前端智能体体验。不覆盖首页可视化、BioRender、TE taxonomy UI 或普通内容页样式。

2 当前模式划分

- Deep Think 是轻量模式：单模型工具增强推理，不显示六阶段工作流，适合序列、关系、分类、表达和基因组位置等直接查询。
- Agent 是重型模式：异步 run 加 worker，显示 Understanding、Planning、Collecting、Executing、Integrating、Writing 六个阶段，适合机制、文献证据、图谱分析和多步综合。
- 前端入口为 `agent.php` 和 `assets/js/pages/agent.js`。Deep Think 调用 `api/deep_think_stream.php`；Agent 创建 run 调用 `api/agent_runs.php`，轮询状态调用 `api/agent_run_status.php`。

3 本轮修复

问题	修复方式
Writing 超时配置未生效	移除 Agent 和 Deep Think 中对 <code>llm_answer_chat_timeout</code> 的 20 秒硬上限，使 <code>config.local.php</code> 中的 40 秒配置真实生效； <code>reasoner timeout</code> 也尊重配置值。
位置问题错路由	在实体归一化和意图识别中补充“位于哪里”、“在哪里”、“定位”、“基因组位置”、“染色体位置”等 <code>genome/location</code> 触发词； <code>expression</code> 判断仍早于 <code>genome</code> ，避免表达问题被误判。
sufficiency 超时后过早停止	当 <code>sufficiency LLM</code> 无可用结果且非 <code>hard-stop intent</code> 仍有 <code>primary path</code> 未执行插件时，继续推荐剩余 <code>primary path</code> ，不再直接判定证据充分。
Agent 过程旁白消耗 LLM	Agent 常规 <code>analysis</code> 、 <code>planning</code> 、 <code>tool selected</code> 、 <code>tool result</code> 、 <code>reflection</code> 、 <code>synthesizing</code> 事件改为模板优先，减少 <code>narrator LLM</code> 调用和 6 秒级超时噪声。
陈旧 run 不会失败	在状态查询层增加 <code>stale watchdog</code> ： <code>pending</code> 超过 30 秒未启动标记失败； <code>running</code> 超过 <code>agent_execution_timeout + 30</code> 秒标记失败。

4 插件职责

- Entity Resolver: 稳定实体名称、别名链和 broad alias 边界。
- Graph Plugin: 查询本地图谱中的实体邻域和结构化关系。
- Graph Analytics Plugin: 执行全局排名、计数、关联度和拓扑类查询。
- Cypher Explorer Plugin: 在固定模板不足时生成只读 Cypher 探索查询。
- Sequence、Genome、Expression、Tree Plugin: 分别提供序列、基因组位置、表达和分类谱系信息。
- Literature、Literature Reading、Citation Resolver: 检索文献、综合论文证据、归一化引用。

5 Mermaid 流程图源码

下面的 Mermaid 代码按人工语法检查规则编写：节点 ID 使用 ASCII，标签使用双引号，判断节点使用花括号，所有 subgraph 均闭合，class 定义位于末尾。

flowchart TD

```
U["User question on agent.php"] --> JS["agent.js reads TEKG_AGENT_CONFIG"]
JS --> M{"Selected mode"}
M -->|Deep Think| DT_API["POST api/deep_think_stream.php"]
M -->|Agent| AR_CREATE["POST api/agent_runs.php"]
```

```
subgraph FE["Frontend runtime"]
```

```
  JS --> DT_UI["Deep thinking panel without six stage graph"]
  JS --> AG_UI["Agent six stage workflow"]
  AG_UI --> POLL["Poll api/agent_run_status.php with after sequence"]
  POLL --> RENDER["Render stage state, tool cards, answer, or failure"]
```

```
end
```

```
subgraph CFG["Runtime configuration"]
```

```
  LOCAL["api/config.local.php"] --> BOOT["tekg_agent_config"]
  BOOT --> MODELS["deepseek-v4-flash models and timeout values"]
  MODELS --> LLM["TekgAgentLlmClient"]
  LLM --> RELAY{"llm_relay_url configured"}
  RELAY -->|yes| RELAY_CALL["POST relay chat endpoint"]
  RELAY -->|no| PROVIDER_CALL["Direct provider call"]
```

```
end
```

```
subgraph DT["Deep Think path"]
```

```
  DT_API --> DT_SVC["DeepThinkService"]
  DT_SVC --> DT_ANALYZE["EntityNormalizer analyzes intent and entities"]
  DT_ANALYZE --> DT_ENTITY["Entity Resolver"]
```

```

DT_ENTITY --> DT_ROUTE{"Simple deterministic route"}
DT_ROUTE -->|sequence| DT_SEQ["Sequence Plugin"]
DT_ROUTE -->|relationship| DT_GRAPH["Graph Plugin"]
DT_ROUTE -->|classification| DT_TREE["Tree Plugin"]
DT_ROUTE -->|expression| DT_EXPR["Expression Plugin"]
DT_ROUTE -->|genome| DT_GENOME["Genome Plugin"]
DT_ROUTE -->|mechanism or papers| DT_LIT["Graph plus Literature plus Reading"]
DT_SEQ --> DT_SYN["Aggregate evidence and citations"]
DT_GRAPH --> DT_SYN
DT_TREE --> DT_SYN
DT_EXPR --> DT_SYN
DT_GENOME --> DT_SYN
DT_LIT --> DT_SYN
DT_SYN --> DT_DET{"Deterministic answer available"}
DT_DET -->|yes| DT_DIRECT["Render full sequence or full relation list"]
DT_DET -->|no| DT_WRITE["LLM direct answer"]
DT_DIRECT --> DT_DONE["SSE answer event"]
DT_WRITE --> DT_DONE
end

```

```

subgraph AG["Async Agent path"]
  AR_CREATE --> SAVE["Save payload.json and state.json"]
  SAVE --> KICK["Local kickoff request or CLI worker"]
  KICK --> WORKER["agent_run_execute marks run running"]
  WORKER --> AG_SVC["AcademicAgentService"]
  AG_SVC --> UNDER["Understanding stage"]
  UNDER --> PLAN["Planning stage"]
  PLAN --> COLLECT["Collecting stage builds plugin queue"]
  COLLECT --> EXEC["Executing stage runs next plugin"]
  EXEC --> PLUGINS{"Plugin selected"}
  PLUGINS --> P_ENTITY["Entity Resolver"]
  PLUGINS --> P_GRAPH["Graph Plugin"]
  PLUGINS --> P_ANALYTICS["Graph Analytics Plugin"]
  PLUGINS --> P_CYPHER["Cypher Explorer Plugin"]
  PLUGINS --> P_SEQ["Sequence Plugin"]
  PLUGINS --> P_GENOME["Genome Plugin"]
  PLUGINS --> P_EXPR["Expression Plugin"]
  PLUGINS --> P_TREE["Tree Plugin"]
  PLUGINS --> P_LIT["Literature Plugin"]
  PLUGINS --> P_READ["Literature Reading Plugin"]
  P_ENTITY --> SUFF["Minimum gate and sufficiency check"]
  P_GRAPH --> SUFF
  P_ANALYTICS --> SUFF

```

```

P_CYPHER --> SUFF
P_SEQ --> SUFF
P_GENOME --> SUFF
P_EXPR --> SUFF
P_TREE --> SUFF
P_LIT --> SUFF
P_READ --> SUFF
SUFF -->|need more evidence| COLLECT
SUFF -->|enough evidence| CITE["Citation Resolver if citations exist"]
CITE --> INTEGRATE["Integrating stage aggregates claims citations limits"]
INTEGRATE --> STRUCT["answer_structure JSON or fallback"]
STRUCT --> WRITE["Writing stage uses trimmed payload"]
WRITE --> DONE_EVENT["done event updates run state"]
DONE_EVENT --> POLL
end

subgraph FIX["Implemented fixes"]
  F1["Fix timeout helpers to honor config 40 seconds"]
  F2["Route location wording to Genome Plugin"]
  F3["On sufficiency LLM timeout continue remaining primary path"]
  F4["Use deterministic templates for routine Agent narration"]
  F5["Mark stale async runs failed in status endpoint"]
end

F1 --> WRITE
F2 --> DT_ANALYZE
F2 --> UNDER
F3 --> SUFF
F4 --> UNDER
F4 --> PLAN
F4 --> EXEC
F5 --> POLL

classDef fix fill:#fff7d6,stroke:#b7791f,color:#111;
class F1,F2,F3,F4,F5 fix;

```