



浙江大學
ZHEJIANG UNIVERSITY

TE-KG：面向人类转座元件功能与疾病 证据整合的知识图谱数据库

中文课程论文初稿

姓名 待填写

学号 待填写

课程 待填写

单位 浙江大学

2026 年 6 月 5 日

摘 要

转座元件 (transposable elements, TEs) 是人类基因组的重要组成部分, 能够通过插入突变、基因组重排、转录调控、表观遗传失衡和调控元件供给等方式影响基因组功能与疾病相关过程 [1, 2, 3, 4, 5, 6]。然而, TE 相关证据长期分散在重复序列注释、分类数据库、表达矩阵、基因组位置、疾病文献和人工整理条目中。研究者若希望回答某一 TE 是否与特定疾病、功能或分子机制相关, 往往需要在多个资源之间切换, 并且难以追踪每一条关系背后的文献证据。本文构建 TE-KG, 一个面向人类转座元件功能与疾病证据整合的知识图谱数据库。该资源以医学文献数据库 (PubMed) 检索、转座元件白名单、实体关系抽取、实体规范化、分类体系构建和图数据库整合为核心流程, 并结合序列、基因组位置、表达数据和网页交互功能, 为 TE 研究提供可浏览、可追踪和可复用的数据入口。当前数据构建流程从 34,788 篇人类转座元件相关候选文献出发, 经白名单筛选和模型辅助抽取后保留 2,308 篇核心文献; 本地资源还包括 5,683,690 条重复序列注释记录、299 条 TE 分类记录、37,868 条表达浏览摘要、143 个表达上下文和 113,604 条表达数据集摘要。TE-KG 进一步提供图谱浏览、路径探索、表达查询、数据下载和自然语言问答助手, 使用户能够从 TE 实体出发追踪疾病、功能、基因、表达和文献证据。该资源的定位不是自动给出未经审查的因果结论, 而是以可追踪证据链支持 TE 疾病机制假设生成和数据库化复用。

关键词: 转座元件; 知识图谱; 数据库; 疾病证据; 文献挖掘; 智能问答

目录

1	背景与概述	1
2	方法	2
2.1	文献检索与候选数据收集	2
2.2	转座元件白名单构建	2
2.3	文献筛选流程	2
2.4	实体与关系抽取	3
2.5	实体规范化与同义词合并	3
2.6	分类体系构建	3
2.7	知识图谱构建	4
2.8	序列、基因组位置与表达数据整合	4
2.9	网页数据库与交互功能实现	4
2.10	自然语言问答助手	4
3	数据记录	5
3.1	文献记录	5
3.2	实体记录	5
3.3	关系记录	5
3.4	分类、序列、位置和表达记录	5
4	技术验证	6
4.1	文献筛选准确性验证	6
4.2	实体规范化验证	6
4.3	关系抽取质量评估	7
4.4	分类体系一致性检查	7
4.5	系统功能验证	7
4.6	自然语言问答验证	7
5	使用说明	7
5.1	查询 TE 基础信息	7
5.2	探索 TE 与疾病的证据链	8
5.3	结合表达和路径探索进行多层证据整合	8
5.4	使用自然语言问答助手	8
6	代码可用性	8
7	数据可用性	8

8 结论	9
参考文献	10

1 背景与概述

转座元件曾长期被视为重复序列或基因组噪声，但现代基因组学研究已经表明，它们是影响基因组结构、转录调控和疾病相关过程的重要组成部分。在人类基因组中，长散在核元件、短散在核元件、长末端重复序列来源元件和复合型逆转录转座元件等类别共同构成了大量重复序列。它们不仅记录了基因组演化历史，也可能通过提供启动子、增强子、剪接位点、转录因子结合位点和染色质调控信号参与宿主调控网络 [2, 3, 4]。

在疾病研究中，TE 的意义更为复杂。一方面，部分 TE 插入事件可以直接破坏基因结构或改变转录产物，从而造成遗传病或增加疾病风险 [6]。另一方面，某些逆转录转座元件在肿瘤中发生低甲基化和重新激活，可能促进插入突变、基因组不稳定和异常转录 [5]。此外，内源性逆转录病毒来源序列和其他 TE 片段还可能参与免疫激活、病毒模拟反应和疾病状态下的调控重塑。由于这些过程横跨序列、位置、表达、功能、疾病和文献证据，TE 研究天然具有多层级和关系密集的特点。

现有资源为 TE 研究提供了重要基础，但它们通常服务于不同数据层。重复序列注释资源适合定位和分类 TE；文献数据库适合检索文章；表达数据资源适合观察转录活跃性；疾病或基因数据库适合查找特定实体。对于单点查询而言，这种分工是有效的；但对于机制性问题而言，研究者常常需要把多个层面的证据重新拼接。例如，若用户希望理解 L1HS 与癌症之间的关系，仅知道其分类或序列并不足够；用户还需要知道相关疾病关系来自哪些文献、是否涉及插入突变或低甲基化、相关基因或功能是什么、表达证据是否支持该背景，以及这些证据能否导出并复查。

知识图谱为这种多源异构证据提供了合适的数据组织方式。生物医学知识图谱已经被用于连接疾病、基因、药物、表型和文献，从而支持关系浏览、证据整合和假设优先级排序 [7, 8]。对于 TE 研究而言，知识图谱的价值不在于替代生物学实验，也不在于自动判定因果强度，而在于把 TE、疾病、功能、基因、蛋白、RNA、表达上下文和文献证据放入同一可追踪网络。用户可以沿图谱边检查证据来源，而不是在孤立表格和文献摘要之间反复切换。

本文构建的 TE-KG 面向人类转座元件研究，目标是形成一个可浏览、可审查、可扩展的知识图谱数据库资源。该资源整合三类能力：第一，围绕 TE 实体组织分类、序列、位置和表达上下文；第二，从文献和结构化数据中整理 TE 与疾病、功能、基因和分子实体之间的关系；第三，通过网页界面和自然语言问答助手支持用户进行证据查询、图谱探索和结果导出。本文按照数据资源论文的写法，重点描述 TE-KG 的构建方法、数据记录、技术验证和使用方式。

2 方法

2.1 文献检索与候选数据收集

TE-KG 的文献数据构建以医学文献数据库 (PubMed) 为主要入口。检索式结合医学主题词和自由词, 覆盖 “DNA Transposable Elements”、“retrotransposon”、“transposon”、“retrotransposons”、“transposons”、“Retrotransposition” 和 “transposition” 等术语, 并限定在人类或智人相关语境中。根据队友的数据构建记录, 检索覆盖截至 2026 年 4 月 13 日的文献, 共获得 34,788 篇候选文章。该检索策略的目的不是在第一步获得完全精确的 TE 文章集合, 而是先形成较高召回率的候选文献池, 再通过 TE 名称白名单、模型辅助抽取和人工验证逐步提高特异性。

文献记录至少保留 PMID、标题、摘要、发表年份和期刊信息。由于 PubMed 主要提供文献元数据和摘要入口, 而不提供期刊影响因子等评价指标 [9], 因此 TE-KG 在数据设计中将文献证据与期刊元数据分开处理。关系是否有文献支持, 取决于是否存在可追踪的 PMID 和对应文本证据; 期刊层面的附加信息只能作为辅助元数据, 不能替代关系本身的证据判断。

2.2 转座元件白名单构建

候选文献检索之后, TE-KG 构建了用于筛选和实体触发的人类转座元件白名单。该白名单主要来自两类资源: 一类是 RepeatMasker 注释中的人类 TE 名称, 另一类是 Repbase 中的人类 TE 标识符及关键词行文本 [10, 11]。白名单的功能是为标题、摘要和模型输出提供候选 TE 名称约束, 从而降低普通词汇、非人类物种转座元件和宽泛机制词造成的误匹配。

白名单本身并不被视为最终事实来源。由于不同资源中的 TE 命名粒度不同, 同一元件可能同时以家族、亚家族、共识序列或注释名称出现; 部分名称还可能与普通英文词或其他生物学术语重合。因此, 白名单被用于候选识别和筛选, 而最终进入图谱的实体仍需要经过规范化和人工校正。

2.3 文献筛选流程

TE-KG 采用两阶段筛选流程。第一阶段使用白名单在候选文章标题和摘要中进行匹配, 从初始候选集中保留 5,362 篇可能讨论人类 TE 的文章。随后, 系统调用大语言模型对这些文章进行结构化信息抽取, 要求模型识别与人类 TE 相关的实体和实体关系, 并按照固定结构输出结果。第二阶段再次基于白名单检查模型输出, 排除没有识别到人类 TE 实体的文章, 最终保留 2,308 篇核心文章。同时, 1,803 篇文章被标记为可能存在 TE 遗漏, 用于后续人工检查和误差分析。

这种流程体现了数据库构建中的一个重要原则: 自动筛选结果需要保留中间状态。被排除、被保留和被标记待检查的文章都应当可以回溯, 因为它们分别对应高置信排除、

核心证据来源和潜在错误来源。这样可以在后续更新中重新审查筛选边界，而不是只保留最终结果。

2.4 实体与关系抽取

在结构化抽取阶段，模型被要求只处理人类 TE 相关证据，并关注活性、致病性、表达异常、插入突变和 DNA 损伤等语境。抽取对象包括转座元件、疾病、功能、突变、基因、RNA、蛋白、糖类、脂类、肽类、药物和毒素等实体类型。关系被组织为因果关系、调控关系、相互作用、关联关系和遗传信息流关系五类语义框架。该分类既覆盖 TE 插入、调控、表达和疾病关联，也为后续图谱浏览和路径分析提供统一的关系层。

为降低自由生成带来的不可控性，抽取提示词约束模型输出为固定结构，并要求每篇文章中的同一实体只出现一次。每个实体需要给出名称和简短描述，每条关系需要给出来源实体、关系谓词、目标实体和简短说明。模型输出不是直接等同于最终事实，而是作为候选结构化记录，后续仍需接受白名单检查、实体规范化和人工质量评估。

2.5 实体规范化与同义词合并

实体规范化是 TE-KG 构建中的关键步骤。TE 名称可能存在大小写差异、标点差异、资源命名差异和分类粒度差异；疾病、功能、基因和分子实体也可能存在同义词或缩写。为减少重复节点和关系碎片化，TE-KG 对同类型实体采用 Ratcliff/Obershelp 字符串相似度方法进行聚类，相似度阈值设为 80%[12]。聚类结果随后经过人工校正，用于建立同义词到规范名称的映射。

规范化流程保留两个层面的信息。第一层是规范实体名称，用于图数据库节点和关系查询；第二层是别名和来源记录，用于解释某个文献或数据源中出现的原始名称如何映射到规范实体。对于无法可靠解析的名称，应保留为候选实体或待审查记录，而不是直接进入核心图谱。该策略可以降低错误合并对关系网络造成的扩散影响。

2.6 分类体系构建

TE 分类体系主要基于 Repbase 注释；对于 Repbase 中未记录或分类不完整的转座元件，使用 RepeatMasker 分类作为补充。为兼顾分类严谨性和图谱覆盖度，TE-KG 构建两套层级树：第一套仅包含在 Repbase 或 RepeatMasker 中有明确注释的 TE；第二套以第一套为基础，纳入知识图谱中出现的全部 TE 实体。前者用于稳定分类浏览，后者用于覆盖文献抽取中出现但分类信息不完整的实体。

疾病分类体系以国际疾病分类第十一次修订版为主要参考 [13]。考虑到单基因病、炎症相关表型和 TE 诱导的基因组不稳定表型在标准疾病层级中可能分散在多个高层类别，TE-KG 在保留标准分类参考的同时，对难以归入单一主类的疾病或表型设置辅助分支。该设计的目标不是重建疾病本体，而是为 TE-疾病关系浏览提供更适合数据库检索的分组方式。

2.7 知识图谱构建

TE-KG 采用图数据库组织实体与关系。图数据库适合表达多类型节点和多跳关系, 并支持从某个 TE 出发追踪疾病、功能、基因、文献和表达上下文之间的连接 [14]。图谱节点包括 TE、疾病、功能、突变、基因、RNA、蛋白、药物、毒素和文献等类型。关系记录保留来源实体、目标实体、关系语义、描述、证据来源和 PMID 追踪字段。

图谱构建遵循证据优先原则。TE-KG 不把文献数量、期刊元数据或模型判断直接等同于因果强度, 而是把它们拆分为可检查字段。用户在浏览某条关系时, 应能够看到该关系对应的来源文献、抽取描述和相关实体, 而不是只看到一个不可解释的分数。这样的设计有利于后续人工审查、导出复用和版本更新。

2.8 序列、基因组位置与表达数据整合

除了文献关系, TE-KG 还整合了 TE 研究所需的基础上下文。序列层面用于提供共识序列、长度和来源说明; 基因组位置层面用于提供代表性位点或注释记录; 表达层面用于描述 TE 在不同组织、细胞系或疾病相关样本中的表达分布。当前本地数据中, RepeatMasker 注释文件包含 5,683,690 条记录; TE 分类表包含 299 条记录; 表达模块包含 37,868 条浏览摘要、143 个表达上下文和 113,604 条数据集摘要。

这些数据层在图谱中承担不同角色。序列和位置帮助用户确认 TE 实体的基础属性; 表达数据帮助用户判断某个 TE 是否在特定组织或细胞背景下具有活跃性; 文献关系帮助用户追踪 TE 与疾病、功能和分子实体之间的证据。TE-KG 的核心价值正在于把这些层次连接起来, 使用户能够从一个 TE 条目进入多维证据空间。

2.9 网页数据库与交互功能实现

TE-KG 提供面向普通研究者的网页入口。实体浏览页面支持用户按名称、分类和关键词查找 TE; 图谱页面支持用户查看局部关系网络、展开节点和检查边信息; 路径探索页面支持用户查询 TE、疾病、基因或功能之间的连接路径; 表达页面支持用户查看不同数据集和上下文中的 TE 表达模式; 下载页面支持用户获取可复用数据表。

交互界面的设计目标不是展示复杂视觉效果, 而是降低证据审查成本。对于数据库论文而言, 网页功能应服务于可追踪性: 用户需要知道某个节点是什么、某条边代表什么、该边由哪些文献或数据支持、当前图谱能否导出以及导出的结果能否复现。后续正式稿应结合数据库截图展示这些功能, 而不使用难以审查的装饰性流程图。

2.10 自然语言问答助手

TE-KG 还提供自然语言问答助手, 用于帮助用户以普通问题访问数据库证据。问答助手将用户问题解析为实体、意图和所需证据层, 再调用分类、序列、基因组位置、

表达、图谱关系、文献和引用等数据模块，最后由模型整合为自然语言答案。其重点是把数据库查询过程转化为可理解回答，而不是生成脱离证据的数据解释。

问答助手在论文中的定位需要保持清晰。它不是原始科学证据来源，也不替代人工判断；它是数据库证据的检索、整合和解释入口。对于机制类问题，系统应明确区分数据库中存在的关系记录、文献支持、模型整合出的解释和仍然缺失的信息。对于中文用户，问答过程和最终回答还应保持语言一致，避免中英文混杂影响理解。

3 数据记录

3.1 文献记录

文献记录以 PMID 为核心标识符，保存标题、摘要、发表年份、期刊和检索来源等元数据。当前数据构建流程从 34,788 篇候选文章出发，经白名单筛选保留 5,362 篇候选文章，并在模型辅助抽取和二次筛选后保留 2,308 篇核心文章。此外，1,803 篇文章被标记为可能遗漏 TE 实体，需要在后续版本中继续检查。正式定稿时，文献记录表应进一步列出可公开字段、字段含义、记录数量和下载方式。

3.2 实体记录

实体记录覆盖 TE、疾病、功能、突变、基因、RNA、蛋白、糖类、脂类、肽类、药物和毒素等类型。每个实体至少需要包含规范名称、实体类型、别名、来源和描述。对于 TE 实体，还应连接分类层级、序列来源和表达摘要；对于疾病实体，应连接疾病分类；对于基因、RNA 和蛋白实体，应保留其与 TE 或疾病关系的来源文献。

3.3 关系记录

关系记录用于描述两个实体之间的语义连接。每条关系至少包含来源实体、目标实体、关系类别、关系描述、来源文献和审查状态。当前图数据库中的节点总数、关系总数、各类关系数量和 PMID 支持比例仍需从运行数据库中统计，本文初稿不编造这些结果。正式稿应使用表格展示不同实体类型和关系类型的规模，并在补充材料中提供字段说明。

3.4 分类、序列、位置和表达记录

分类记录包括 TE 分类树和疾病分类树。当前 TE 分类表包含 299 条记录。序列记录用于保存 TE 共识序列及来源说明；基因组位置记录用于保存注释来源、染色体、起止位置和代表性位点；表达记录用于保存不同组织、细胞系和数据集中的表达摘要。当前表达资源包含 37,868 条 TE 浏览摘要、143 个表达上下文和 113,604 条表达数据集摘要。

表 1: 当前可确认的数据记录规模

数据层	当前记录数	说明
候选文献	34,788	PubMed 检索获得的人类 TE 相关候选文章
白名单初筛文献	5,362	标题或摘要命中 TE 白名单的候选文章
核心文献	2,308	二次筛选后保留的 TE 相关文章
待检查文献	1,803	可能存在 TE 实体遗漏的文章
重复序列注释	5,683,690	本地 RepeatMasker 注释记录
TE 分类记录	299	本地 TE 分类表记录
表达浏览摘要	37,868	表达模块的 TE 浏览摘要记录
表达上下文	143	组织、细胞系或数据集上下文
表达数据集摘要	113,604	TE 与数据集层面的表达摘要

4 技术验证

4.1 文献筛选准确性验证

文献筛选质量通过人工抽样进行评估。根据队友的数据构建记录，人工复核覆盖三组文章：第一组为初筛阶段移除的 27,108 篇文章，第二组为二次筛选阶段移除的 5,362 篇文章，第三组为图谱整合阶段标记的 1,803 篇疑似遗漏文章。每组随机抽取 50 篇文章进行人工检查。初筛移除文章的正确过滤率为 100%，二次筛选移除文章的正确过滤率为 94%，整合阶段标记文章的判断正确率为 96%。

置信区间估计进一步说明了筛选流程的可靠性。初筛移除组使用 Clopper–Pearson 精确方法估计 95% 置信区间，为 92.9% 至 100%；二次筛选组和整合标记组使用 Wilson 区间，分别为 83.78% 至 97.94% 和 93.19% 至 97.9%。错误来源主要包括部分人类 TE 未出现在 Repbase 或 RepeatMasker 白名单中，以及模型在抽取阶段遗漏了真实 TE 实体。

4.2 实体规范化验证

实体规范化的验证重点是同义词合并是否减少重复实体，同时不错误合并不同实体。TE-KG 使用字符串相似度聚类作为候选合并工具，再由人工校正建立规范名映射。正式稿应补充规范化前后的实体数量、人工校正样例和高风险命名案例。对于 TE 实体，尤其需要检查家族名、亚家族名和具体插入实例之间的边界，避免把宽泛家族关系误写成具体亚家族关系。

4.3 关系抽取质量评估

关系抽取质量需要从两个层面评估。第一是结构层面，即模型输出是否符合固定格式，实体类型和关系类型是否在允许范围内。第二是语义层面，即关系描述是否真正由摘要文本支持，方向是否正确，是否把共现误判为机制关系。正式稿应补充抽样关系的人工复核结果，并区分因果、调控、相互作用、关联和遗传信息流等关系类型的错误率。

4.4 分类体系一致性检查

分类体系检查包括 TE 分类和疾病分类两个方向。TE 分类需要与 Repbase 和 RepeatMasker 对照，记录直接匹配、补充匹配和待审查条目；疾病分类需要与国际疾病分类体系对照，记录标准类目、辅助类目和无法稳定归类的疾病。分类体系的目标是服务检索和浏览，因此应优先保证层级清晰、来源可追踪和例外可解释。

4.5 系统功能验证

系统功能验证应围绕代表性用户问题展开，而不是只检查页面是否能打开。建议保留以下最小验证集：查询 L1HS 的分类和序列长度；查询 L1HS 的代表性基因组位置；查询某一 TE 的表达上下文；查询 L1HS 与癌症相关的图谱关系；导出局部图谱和证据表。每个验证问题都应记录输入、调用的数据模块、返回结果和人工判断。

4.6 自然语言问答验证

问答助手需要单独验证，因为它直接影响用户对数据库的理解。验证重点包括：是否正确识别 TE 实体；是否调用与问题相关的数据模块；是否避免把页面导航或期刊元数据当作科研证据；是否能够把图谱、序列、表达和文献结果整合为简明回答；是否在证据不足时明确说明缺口。中文问题应得到中文思考内容和中文最终回答，英文问题应保持英文输出。

5 使用说明

5.1 查询 TE 基础信息

用户可以从实体浏览页面输入 TE 名称，例如 L1HS，进入对应条目后查看其分类、别名、序列来源、代表性基因组位置和表达摘要。对于只需要基础信息的用户，该流程可以快速回答“该 TE 属于哪一类”“是否有共识序列”“是否存在代表性位置”等问题。若用户需要进一步追踪疾病关系，则可以从条目页进入图谱视图。

5.2 探索 TE 与疾病的证据链

对于疾病机制问题，用户可以在图谱页面以 TE 或疾病为起点加载局部关系网络。以 L1HS 为例，用户可以查看其与癌症、遗传病或其他疾病实体之间的关系，并继续展开相关功能、基因或 RNA 节点。每条边应提供关系描述和文献来源，使用户能够判断该关系是插入事件、表达异常、低甲基化、一般关联还是其他机制线索。

5.3 结合表达和路径探索进行多层证据整合

当用户关心某个 TE 是否在特定组织或疾病背景中活跃时，可以结合表达页面和路径探索页面使用。表达页面提供不同数据集和上下文中的表达摘要，路径探索页面则帮助用户查找 TE、基因、功能和疾病之间的连接。两者结合可以支持更具体的问题，例如某个 TE 是否在某类细胞系中高表达，并且是否通过图谱关系连接到相关疾病或调控功能。

5.4 使用自然语言问答助手

自然语言问答助手适合处理综合性问题，例如“整合一下 L1HS 的信息”或“L1HS 如何导致疾病”。系统会先识别问题中的实体和意图，再调用相应数据模块，最后生成带证据边界的回答。用户应把问答结果视为数据库证据的整理摘要，并在需要发表或深入研究时回到图谱边、下载表和 PMID 记录进行核验。

6 代码可用性

TE-KG 的网页系统、数据处理流程和验证脚本应在正式发布版本中提供稳定的代码入口和版本说明。课程论文阶段可以先说明代码位于本地项目仓库，正式公开前需要完成敏感配置清理、运行说明整理、依赖版本记录和示例数据准备。代码可用性声明不应包含本地数据库名称、个人密钥、内部端口或临时脚本路径。

7 数据可用性

TE-KG 的数据开放应遵循可发现、可访问、可互操作、可复用（FAIR）原则 [15]。正式发布时，建议提供实体表、关系表、文献证据表、分类表、表达摘要表和示例查询结果，并为每个文件提供字段说明、生成日期、版本号和引用方式。对于来源受限或许可不明确的数据，应说明原始来源和复用边界；对于可公开复用的数据，应优先提供稳定下载地址和校验信息。

8 结论

本文构建了 TE-KG，一个面向人类转座元件功能与疾病证据整合的知识图谱数据库资源。该资源以文献检索、TE 白名单、模型辅助抽取、实体规范化、分类体系和图数据库构建为核心流程，将 TE 基础属性、疾病关系、功能关系、表达上下文和文献证据组织到同一可追踪框架中。与孤立表格或普通文献检索相比，TE-KG 更强调关系证据的可浏览性、可导出性和可审查性。后续工作将继续补充图数据库规模统计、关系抽取质量评估、更多使用案例和公开数据版本，使该资源更稳定地服务于 TE 疾病机制研究。

参考文献

- [1] International Human Genome Sequencing Consortium. Initial sequencing and analysis of the human genome. *Nature*, 409:860–921, 2001.
- [2] Richard Cordaux and Mark A. Batzer. The impact of retrotransposons on human genome evolution. *Nature Reviews Genetics*, 10:691–703, 2009.
- [3] Edward B. Chuong, Nels C. Elde, and Cedric Feschotte. Regulatory activities of transposable elements: from conflicts to benefits. *Nature Reviews Genetics*, 18:71–86, 2017.
- [4] Guillaume Bourque, Kathleen H. Burns, Mary Gehring, Vera Gorbunova, Andrei Seluanov, Molly Hammell, Michael Imbeault, Zsofia Izsvak, Henry L. Levin, Todd S. Macfarlan, Dixie L. Mager, and Cedric Feschotte. Ten things you should know about transposable elements. *Genome Biology*, 19:199, 2018.
- [5] Kathleen H. Burns. Transposable elements in cancer. *Nature Reviews Cancer*, 17:415–424, 2017.
- [6] Louise M. Payer and Kathleen H. Burns. Transposable elements in human genetic disease. *Nature Reviews Genetics*, 20:760–772, 2019.
- [7] Daniel S. Himmelstein, Antoine Lizée, Christine Hessler, Leo Brueggeman, Sabrina L. Chen, Dexter Hadley, Ari Green, Pouya Khankhanian, and Sergio E. Baranzini. Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726, 2017.
- [8] Payal Chandak, Kexin Huang, and Marinka Zitnik. Building a knowledge graph to enable precision medicine. *Scientific Data*, 10:67, 2023.
- [9] National Library of Medicine. Pubmed overview. <https://pubmed.ncbi.nlm.nih.gov/about/>. Accessed: 2026-06-05.
- [10] Jerzy Jurka, Vladimir V. Kapitonov, Adam Pavlicek, Piotr Klonowski, Oleksiy Kohany, and Jurka Walichiewicz. Repbase update, a database of eukaryotic repetitive elements. *Cytogenetic and Genome Research*, 110:462–467, 2005.
- [11] Arian F. A. Smit, Robert Hubley, and Phil Green. Repeatmasker open-4.0. *Institute for Systems Biology*, 2015. <https://www.repeatmasker.org/>.
- [12] John W. Ratcliff and David E. Metzener. Pattern matching: The gestalt approach. *Dr. Dobb’s Journal*, 13(7):46, 1988.

- [13] World Health Organization. International classification of diseases 11th revision. <https://icd.who.int/>. Accessed: 2026-06-05.
- [14] Neo4j. Neo4j graph database. <https://neo4j.com/>. Accessed: 2026-06-05.
- [15] Mark D. Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E. Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.