



浙江大學
ZHEJIANG UNIVERSITY

TE-KG Proposal

面向转座元件疾病证据整合的知识图谱资源

项目 TE-KG

版本 2026-05-30 draft

单位 浙江大学

2026 年 5 月 30 日

摘 要

转座元件 (transposable elements, TEs) 占据人类基因组的重要部分, 并通过插入、重排、调控元件供给和转录调控等方式参与基因组演化与疾病相关过程 [1, 2, 3, 4]。然而, TE 相关证据通常分散在基因组注释、表达数据、文献摘要、疾病关联和人工整理的知识条目中, 研究者难以在同一界面内追踪 “TE-分子实体-疾病-文献证据” 的完整证据链。本 proposal 以已经实现的 TE-KG 本地 pilot resource 为基础, 提出一个面向 TE 疾病机制研究的知识图谱资源建设方案。当前 **tekg3** 运行时已经由 Neo4j、PHP API、浏览器 G6 图谱、MySQL 表达摘要和 PubMed 元数据增强流程共同支撑; 只读检查确认 live Neo4j 统计接口包含 11,415 个节点和 13,696 条关系, 代表性 TE 条目 L1HS、AluJb 和 SVA 可解析。方案的核心假设是: 若将 TE taxonomy、疾病关联、表达入口和 PubMed 证据元数据整合为可追踪、可导出、可验证的知识图谱, TE 相关机制假设的发现和证据审查将比孤立页面或人工检索更透明、更可复用。

目录

1	研究背景与科学问题	1
2	核心假设与总体目标	1
3	已有基础与初步资源	2
3.1	运行时系统	2
3.2	文献证据与 2025 年影响因子元数据	2
3.3	图谱证据浏览与导出	2
4	研究内容与技术路线	3
4.1	Aim 1: 巩固 TE-KG 运行时图谱与 API contract	3
4.2	Aim 2: 建立可审查的 TE-疾病文献证据层	4
4.3	Aim 3: 建立开放、可导出、可复用的用户工作流	4
5	创新点	4
6	数据开放与 FAIR 计划	4
7	风险、边界与质量控制	5
8	预期成果	5
	参考文献	7

1 研究背景与科学问题

TEs 不只是基因组中的重复序列负担。已有研究显示，逆转座元件和其他 TE 类群能够影响基因组结构、调控网络和物种演化 [2, 3, 4]。在人类疾病研究中，TE 插入、TE 转录失控、TE 衍生调控元件和内源性逆转录病毒序列均可能与癌症、遗传病及其他病理过程相关 [5, 6]。这些研究共同提出一个数据组织问题：TE 相关证据同时具有序列、分类、基因组位置、表达、疾病、功能和文献维度，单一表格或单一检索入口难以表达实体间关系。

知识图谱适合表示这种异质、关系密集的生物医学证据结构。已有生物医学知识整合工作表明，将多源实体和关系组织为可计算图谱，有助于复用既有知识并支持假设优先级排序 [7]。TE-KG 的科学问题因此可以表述为：如何把 TE 分类、疾病关联、表达证据和 PubMed 文献证据组织为一个可验证、可浏览、可导出的图谱资源，并避免把文献数量、期刊指标或自动化回答误写成未经验证的因果强度？

2 核心假设与总体目标

本 proposal 的核心假设是：一个以 Neo4j 为运行时核心、以 API contract 和浏览器 smoke test 为质量门禁、以 PubMed 元数据为证据层的 TE 知识图谱，可以为 TE 疾病机制研究提供比静态数据表更清晰的证据追踪能力。该假设不预设任一 TE-疾病关系为因果关系，而是把图谱关系、支持 PMID、期刊元数据覆盖率和前端证据表作为可审查的 evidence support。

总体目标是将当前 TE-KG pilot resource 发展为一个可公开、可复现、可审计的 TE 疾病知识图谱资源。具体目标包括：

1. 建立以 `tekg3` 为唯一 runtime target 的图谱资源层，稳定表示 TE、疾病、功能、基因、蛋白、药物、文献等实体及其关系。
2. 建立文献证据层，将 PubMed PMID、标题、期刊、年份、MeSH/关键词、作者、基金、化学物质和引用信息与既有 Paper 节点和 `BIO_RELATION` 关系连接。
3. 建立用户可审查的前端证据工作流，使研究者能够从图谱边跳转到 PubMed 证据表，并导出当前可见子图和所选边的证据 CSV。
4. 建立开放数据与 FAIR 元数据计划，使代码、处理后数据、图谱导出、证据元数据和文档能够在许可允许范围内公开发布 [8, 9]。

3 已有基础与初步资源

3.1 运行时系统

TE-KG 当前已经是一个本地 PHP + browser JavaScript + Neo4j + MySQL 系统。核心页面仍位于项目根目录, 包括 `index.php`、`browse.php`、`preview.php`、`expression.php`、`expression_detail.php` 和 `path_finder.php`。主要运行时入口如下:

- 图谱 API: `api/graph.php` 和 `api/graph_service.php`。
- Taxonomy API: `api/taxonomy.php`。
- Expression API: `api/expression_data.php`;
`api/expression_repository.php`。
- Expression runtime 根目录: `data/bulk_expression_web`。

系统不再使用旧的 `data/raw/new_data/bulk_expression_web` 路径作为 `expression runtime` 根目录。

当前 live 检查确认, Neo4j 配置解析到 `tekg3`, RETURN 1 可执行, 代表性 TE 名称 `AluJb`、`L1HS` 和 `SVA` 可解析。homepage stats API 以 Neo4j 为统计来源, 报告当前运行时包含 11,415 个节点和 13,696 条关系。另一个 Neo4j 检查确认 225 个 TE 节点; 该检查使用的 `BIO_RELATION` 计数口径不同, 因此正式规模表述以 live Neo4j 统计接口的节点和关系总数为主。

3.2 文献证据与 2025 年影响因子元数据

TE-KG 已经完成 PubMed 元数据增强流程。当前 PubMed PMID inventory 包含 2,308 个唯一 PMID, 完整抓取写入 2,308 条 PubMed metadata records, 失败数为 0。PubMed XML 提供 PMID、DOI、标题、摘要可用性、期刊、发表年份、发表类型、MeSH term、关键词、作者、单位、基金、化学物质和引用等字段; PubMed 本身不提供影响因子, 影响因子必须来自外部期刊指标映射 [10]。

项目已将 2025 年影响因子元数据映射到现有 `Paper` 节点。映射结果显示, 2,037 个 `Paper` 节点具有 2025 年影响因子元数据, 271 个 `Paper` 节点保持 `null / unmatched`。该影响因子来源为项目内部批准的 `impact_factor_package_2025`, 不能表述为官方 JCR direct export。所有缺失值必须保留为 `null`、`unknown` 或 `unmatched`, 不允许由模型或人工推断填补。

3.3 图谱证据浏览与导出

G6 图谱工作区已支持 evidence support UX。Graph API edge payload 包含 PMID 支持数、metric coverage、IF mean/max 等 `support_*` 字段以及 eager evidence records。

前端将边宽映射到 PMID 支持数，将边透明度映射到 metric coverage，并在边卡片中显示 PubMed evidence table。这里的 `support_*` 字段只表示 evidence support，不表示 confidence。

图谱导出已支持当前可见子图的 nodes CSV、edges CSV 和 canvas PNG。SVG 导出尚未实现，界面仅保留 disabled 的 SVG Soon 状态。浏览器 smoke 当前通过 LINE1 查询；TE tree/load 回归检查确认 LINE1 动态图加载为 95 nodes / 103 edges，L1HS 动态图加载为 54 nodes / 58 edges，taxonomy tree 包含 1,632 nodes / 1,631 edges，并恢复了 L1HS 在 Class I / LINE 层级下的路径。




图 1: TE-KG pilot resource 的当前运行时与证据元数据快照。Panel a 显示 live Neo4j 统计接口和 PubMed metadata pipeline 的主要规模；Panel b 显示 2025 年影响因子元数据在 Paper 节点上的 matched 与 null/unmatched 状态；Panel c 显示浏览器 smoke 覆盖的代表性图谱查询规模。图中数据来自本仓库当前只读检查和已归档完成计划，源表见 `docs/proposal/tekg_proposal_figure_data.csv`。

4 研究内容与技术路线

4.1 Aim 1: 巩固 TE-KG 运行时图谱与 API contract

Aim 1 将把 `tekg3` 固化为 proposal 阶段的唯一 Neo4j runtime target，并继续以 `api/graph.php`、`api/graph_service.php`、`api/taxonomy.php` 和 expression API 作为稳定入口。该目标的重点不是新增第二套 taxonomy truth source，而是维护当前 Neo4j/API canonical 规则。任何 taxonomy、expression 或 graph runtime 变更都应通过现有检查验证，包括 runtime DB config、API contracts、expression path consistency、G6 browser smoke 和 no legacy DB fallback。

4.2 Aim 2: 建立可审查的 TE-疾病文献证据层

Aim 2 将以当前 PubMed metadata 和 2025 年影响因子映射为基础，继续完善 Paper.pmid 与 BIO_RELATION.pmid 的证据连接。证据层应明确区分三类信息：第一，文献事实字段，如 PMID、标题、期刊、年份、MeSH term 和 DOI；第二，关系支持字段，如 PMID 支持数和 metric coverage；第三，外部期刊元数据，如 2025 年影响因子。只有第一类和第二类可以直接支撑“关系有文献记录”的表述，第三类只能作为期刊元数据展示，不能被写成关系可信度或因果强度。

4.3 Aim 3: 建立开放、可导出、可复用的用户 workflow

Aim 3 将围绕 preview.php 的图谱工作区形成可复用浏览 workflow。用户应能够从 TE 或疾病节点出发，查看相关实体、展开局部邻域、检查边证据、下载可见子图 CSV/PNG，并保留所选边的 PubMed evidence table。Agent/DeepThink 子系统可作为实验性 evidence-grounded assistant workflow，用于研究型问题的证据包组织和报告草稿，但其输出必须经过 evidence package、evidence walk、report plan 和 integrity gate 约束。该 assistant layer 不应被描述为成熟自治科研代理。

5 创新点

本 proposal 的创新点在于把 TE 研究中常见的多个断裂层面连接为一个可审计的资源 workflow。第一，图谱资源不只提供实体检索，而是把 TE taxonomy、疾病关联、表达入口和文献证据组织到同一运行时。第二，文献支持不是抽象分数，而是可展开的 PMID-level evidence records，研究者能够回到 PubMed 条目检查原始文献信息。第三，2025 年影响因子元数据被明确限制为期刊层面的辅助展示，避免将期刊指标误写成关系 confidence。第四，系统用可运行检查维护 runtime contract，使资源建设过程本身可审计。

6 数据开放与 FAIR 计划

TE-KG 的数据开放策略应遵循 FAIR 原则，即数据和元数据需要可发现、可访问、可互操作、可复用 [8]。在本 proposal 中，原则上可以公开的内容包括项目代码、API contract 文档、处理后的 PubMed metadata JSONL、图谱导出 CSV、可公开的 Neo4j 导出、图谱统计图源数据、检查脚本输出摘要和 proposal 文档本身。第三方或许可受限的数据源需要单独标注来源、许可和再分发限制。

Data Availability statement 的建议文本如下：

The TE-KG source code, processed graph-export tables, proposal figure source data and documentation are planned for public release in a versioned repository. Processed PubMed-derived metadata will be distributed with PMID-level provenance where redistribution is permitted. Third-party resources, including Repbase/RMSK-derived taxonomy inputs and the 2025 impact-factor package used for internal journal metadata mapping, will be released only when licensing permits; otherwise, accession routes, transformation scripts and null/unmatched records will be documented without redistributing restricted source files.

该声明仍需人工确认最终仓库地址、许可证、数据 DOI 或长期归档平台。若某些第三方输入不能公开，应公开 transformation scripts、字段说明、缺失值规则和可复现流程，而不是公开受限源文件。

7 风险、边界与质量控制

本 proposal 的主要风险来自三类边界。第一，taxonomy runtime truth source 仍需持续维护。当前 `api/taxonomy.php` contract 和 TE tree smoke 已通过，但 homepage taxonomy truth-source 检查提示 `index.php` 的 ring chart 仍需核查是否完全使用 Neo4j-backed helper。因此，在正式发布前应把 homepage taxonomy 展示与 runtime canonical source 对齐，或在论文/报告中排除该页面作为核心证据。

第二，文献证据和期刊指标必须避免过度解释。PubMed metadata 支持文献信息组织，不能自动证明关系因果性；2025 年影响因子只表示期刊层面元数据，不应参与 confidence 命名。关系边上的 `support_*` 字段应保持 evidence support 语义。

第三，Agent/DeepThink 子系统仍处于实验性 workflow 阶段。已有 deterministic tests、live targeted plugin checks 和 evidence-walk integrity gate 支撑其可运行性，但 Phase 5C semantic proxy 不能验证生物学事实，也不能证明 claim-level citation support。因此，proposal 中只把 Agent 写作层作为辅助证据组织与报告草稿工具，不把它作为成熟自治发现系统。

8 预期成果

本 proposal 的预期成果包括一个以 `tekg3` 为核心的 TE-KG pilot resource、一个 PubMed PMID-level 文献证据层、一个可导出可浏览的 G6 图谱工作区、一套 Data Availability / FAIR 元数据说明，以及一组可运行检查作为资源质量门禁。若这些目标完成，TE-KG 将能够支持研究者从 TE 实体进入疾病和功能关系，检查 PMID 支持，导

出当前可见子图，并以透明方式区分“已有证据记录”“期刊元数据覆盖”和“仍需人工验证的机制解释”。

参考文献

- [1] International Human Genome Sequencing Consortium. Initial sequencing and analysis of the human genome. *Nature*, 409:860–921, 2001.
- [2] Richard Cordaux and Mark A. Batzer. The impact of retrotransposons on human genome evolution. *Nature Reviews Genetics*, 10:691–703, 2009.
- [3] Edward B. Chuong, Nels C. Elde, and Cedric Feschotte. Regulatory activities of transposable elements: from conflicts to benefits. *Nature Reviews Genetics*, 18:71–86, 2017.
- [4] Guillaume Bourque, Kathleen H. Burns, Mary Gehring, Vera Gorbunova, Andrei Seluanov, Molly Hammell, Michael Imbeault, Zsafia Izsvak, Henry L. Levin, Todd S. Macfarlan, Dixie L. Mager, and Cedric Feschotte. Ten things you should know about transposable elements. *Genome Biology*, 19:199, 2018.
- [5] Kathleen H. Burns. Transposable elements in cancer. *Nature Reviews Cancer*, 17:415–424, 2017.
- [6] Louise M. Payer and Kathleen H. Burns. Transposable elements in human genetic disease. *Nature Reviews Genetics*, 20:760–772, 2019.
- [7] Daniel S. Himmelstein, Antoine Lizée, Christine Hessler, Leo Brueggeman, Sabrina L. Chen, Dexter Hadley, Ari Green, Pouya Khankhanian, and Sergio E. Baranzini. Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726, 2017.
- [8] Mark D. Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.
- [9] Springer Nature. Research data policy. <https://www.springernature.com/gp/authors/research-data-policy>. Accessed: 2026-05-30.
- [10] National Library of Medicine. Pubmed overview. <https://pubmed.ncbi.nlm.nih.gov/about/>. Accessed: 2026-05-30.