



浙江大學
ZHEJIANG UNIVERSITY

TE-KG 研究方案

面向转座元件疾病证据整合的知识图谱资源

项目 TE-KG

版本 2026-05-30 修订稿

单位 浙江大学

2026 年 6 月 3 日

摘 要

转座元件 (transposable elements, TEs) 是人类基因组的重要组成部分, 能够通过插入突变、基因组重排、调控元件供给、表观遗传失衡和转录调控等方式影响基因组功能与疾病相关过程 [1, 2, 3, 4, 5, 6]。然而, TE 相关证据通常分散在分类数据库、重复序列注释、基因组位置、表达数据、疾病关联、文献记录和人工整理的知识条目中。研究者若希望回答某一 TE 是否与特定疾病、功能或分子机制相关, 往往需要在多个孤立资源之间切换, 并且难以追踪每一条关系背后的 PMID 级文献证据。因此, 该项目拟构建一个面向转座元件疾病机制研究的证据链接知识图谱资源, 将 TE 分类体系、基因组与表达上下文、疾病/功能关系和 PubMed 文献证据组织到同一可浏览、可审查、可导出的 TE-KG 工作流中。

该项目的核心假设是: 如果将 TE 相关实体、关系和文献证据组织为以 Neo4j 为核心的知识图谱, 并通过接口契约检查、浏览器回归检查、PMID 级证据表和 FAIR 数据开放计划进行约束, 则该资源能够比孤立表格或人工检索更透明地支持 TE 疾病机制假设的提出与证据审查。这里的 FAIR 指数据和元数据应尽可能可发现、可访问、可互操作和可复用。当前 TE-KG 已有本地初步平台, 包括图谱运行时、PHP 接口、浏览器图谱界面、表达数据入口、PubMed 元数据增强流程和代表性 TE 查询案例。本文在现有平台基础上提出进一步完善数据获取、图谱构建、证据链接、用户工作流、自然语言问答助手和评估体系的研究方案。预期成果是一个可复现、可审计、可扩展的 TE-KG 资源, 使研究者能够从 TE 实体出发追踪疾病/功能关系、检查文献证据、导出局部子图, 并清晰区分“关系有证据记录”“期刊元数据覆盖”和“仍需人工验证的机制解释”。

目录

1	引言	1
2	研究空白与立项依据	1
3	研究目标与具体目标	2
3.1	目标一：构建以 TE 为中心的知识图谱结构	2
3.2	目标二：建立 PMID 级文献证据层	2
3.3	目标三：建立可浏览、可导出、可复现的用户 workflows	3
3.4	目标四：建立面向数据库证据的自然语言问答助手	3
4	研究方法	3
4.1	数据获取与更新流程	3
4.2	实体标准化与图谱构建	3
4.3	文献证据链接	4
4.4	表达、基因组与序列上下文	4
4.5	用户 workflows 与导出	4
4.6	质量控制	5
5	初步基础	5
6	评估方案	5
6.1	覆盖度评估	5
6.2	证据可追踪性评估	6
6.3	代表性案例评估	6
6.4	可复现性与用户 workflows 评估	6
7	预期成果与贡献	6
8	局限性与风险控制	7
9	数据开放与 FAIR 计划	7
10	结论	8
	参考文献	9

1 引言

转座元件长期被视为重复序列，但现代基因组研究已经表明，它们并非单纯的“基因组噪声”。在人类基因组中，LINE、SINE、LTR/ERV、SVA 等 TE 家族不仅构成大量重复序列，也可能参与调控元件形成、转录网络重塑、基因组结构变异和物种特异性调控演化 [1, 2, 3, 4]。在疾病语境中，TE 插入、LINE-1 活化、TE 相关低甲基化、内源性逆转录病毒序列表达和 TE 衍生顺式调控元件均被报道与癌症、遗传病、免疫相关过程及其他病理状态有关 [5, 6, 7]。因此，TE 研究天然具有跨层级证据结构：同一个 TE 条目可能同时涉及分类、序列、基因组位置、表达模式、疾病关联、功能描述和文献证据。

这种跨层级性质给数据组织带来困难。传统数据库或表格常常只覆盖其中一个维度，例如重复序列注释、TE 分类体系、表达矩阵或文献检索结果。它们适合回答“某个条目是否存在”或“某个字段的值是什么”，但不擅长表达“某一 TE 如何通过某类分子关系与疾病证据相连”。对于研究者而言，真正有价值的问题往往不是单点查询，而是关系追踪：L1HS 是否与某些癌症有关？这种关联来自哪些关系类型？有哪些 PMID 支持？相关证据是疾病关系、表达失衡、插入事件还是文献摘要中的一般性陈述？如果这些证据分散在多个页面或数据文件中，人工整合不仅耗时，而且容易混淆证据记录、期刊指标和因果解释。

知识图谱（knowledge graph）适合表达这种异质、关系密集的数据结构。生物医学知识图谱已经被用于整合药物、基因、疾病、表型和文献等多源实体，并支持可计算的知识复用和假设优先级排序 [8, 9]。对 TE 研究而言，知识图谱的价值不在于给出自动化因果结论，而在于把 TE、疾病、功能、基因、蛋白、RNA、表达上下文和 PMID 级证据放到可审查的关系网络中。研究者可以沿着图谱边追踪证据，而不是只阅读孤立的文本摘要。

本研究拟在现有 TE-KG 初步资源的基础上，构建一个面向 TE 疾病机制研究的证据链接知识图谱资源。它将以图数据库运行时为核心，通过数据更新流程、实体标准化、文献证据链接、图谱浏览界面、自然语言问答助手和导出工作流，形成一个可复现的资源建设方案。

2 研究空白与立项依据

TE 相关证据的主要问题不是单一数据源缺失，而是证据维度被切割。一个面向疾病机制的问题通常至少包含四类信息。第一是 TE 自身信息，包括家族/亚家族、共识序列、基因组位置和分类层级。第二是生物医学关系，包括 TE 与疾病、功能、基因、蛋白或 RNA 的连接。第三是上下文证据，包括表达模式、表观遗传调控、组织或细胞类型，以及潜在的疾病状态。第四是文献证据，包括 PMID、标题、期刊、年份、医学主题词（MeSH term）、摘要和引用记录。若这些维度不能在同一资源中互相链接，研究者很难判断某条 TE-疾病关联究竟由哪些证据支撑。

现有工具通常只能覆盖这一链条的一部分。重复序列数据库和基因组浏览器适合定位 TE 序列和注释，但它们不一定提供疾病关系证据。PubMed 能够检索文献，但检索结果本身不组织成以 TE 为中心的关系图谱。表达数据入口可以显示某个 TE 的表达模式，但不直接说明其与疾病、功能或文献证据之间的关系。人工整理的关系表可以列出 TE 与疾病的关联，但若缺少可展开的 PMID 级证据，用户仍然需要回到原始文献逐条核验。

此外，证据解释本身也存在风险。文献数量不能等同于因果强度；期刊影响因子（Impact Factor, IF）和 JCR 分区只是期刊层面元数据，不能作为某条 TE-疾病关系的可信度；自动化问答系统生成的报告也不能替代逐条论断的引用支撑。若资源设计没有显式区分“证据支持”“期刊元数据”和“生物学解释”，用户可能会把“有文献记录”误读为“机制已被证明”。

因此，该项目的立项依据是：TE 疾病机制研究需要一种证据链透明的数据组织方式。TE-KG 不应只是把更多数据堆到同一个页面，而应把实体、关系、证据和导出工作流设计为可审查系统。它的核心任务是让研究者能够从 TE 实体进入图谱关系，再回到 PMID 级证据，并在需要时导出当前可见子图和证据表。

3 研究目标与具体目标

该项目的总体目标是构建一个可公开、可复现、可审计的 TE 疾病知识图谱资源。该资源以 TE 为中心组织疾病、功能、基因、蛋白、RNA、表达上下文和文献证据，支持研究者进行关系浏览、证据核验和机制假设生成。核心假设是：一个带有 PMID 级证据层和明确质量门禁的知识图谱，比孤立表格或人工检索更适合支持 TE 疾病机制研究中的证据追踪。

3.1 目标一：构建以 TE 为中心的知识图谱结构

目标一将建立以 TE 为中心的图谱结构，稳定表示 TE、疾病、功能、基因、蛋白、RNA、药物、论文等实体类型及其关系。该目标的重点不是增加第二套分类事实来源，而是把 TE 分类体系、关系类型和运行时数据入口统一到同一套 Neo4j 支持的图谱结构中。图谱边应保留关系类型、证据来源、PMID 支持和必要的来源追踪字段，使后续证据链接和用户审查有明确数据基础。

3.2 目标二：建立 PMID 级文献证据层

目标二将把 PubMed 元数据与图谱关系连接。文献证据层将保留 PMID、DOI、标题、期刊、年份、摘要可用性、医学主题词、关键词、作者和其他可公开元数据。外部期刊指标可以作为期刊元数据辅助展示，但必须与证据支持分离。该目标的目的是让用户能够从图谱边追踪到具体文献记录，而不是只看到抽象支持分数。

3.3 目标三：建立可浏览、可导出、可复现的用户 workflow

目标三将围绕 TE-KG 图谱工作区、路径查找、实体浏览、表达查看和下载页面形成用户 workflow。研究者应能够完成以下操作：选择 TE 或疾病实体，浏览局部图谱邻域，检查关系证据表，查看表达或基因组上下文，导出可见子图和证据 CSV，并根据代表性案例复现查询过程。该目标的关键评价标准不是界面复杂度，而是证据链是否可追踪、导出是否可复现、关系解释是否保持边界清晰。

3.4 目标四：建立面向数据库证据的自然语言问答助手

目标四将建立面向 TE-KG 的自然语言问答助手，使用户能够用普通问题调用数据库中的分类、序列、基因组位置、表达、图谱关系和文献证据层。该助手的定位不是替代数据库本身或自动给出未经审查的科学结论，而是把用户问题转化为可追踪的数据查询，整合不同证据层的结果，并在回答中明确区分数据库记录、文献支持、推断性解释和缺失信息。该目标的关键评价标准包括：插件或数据模块调用是否与问题相关，证据来源是否可回溯，回答是否避免照搬原始数据，中文和英文问题是否能够得到一致、清晰的解释。

4 研究方法

4.1 数据获取与更新流程

TE-KG 的数据获取将采用脚本化、可追踪的更新流程。第一步是确定 TE 名称、别名和分类层级的候选清单，并将其作为文献检索和实体匹配的约束条件。第二步是在 PubMed 等公开文献资源中构建检索式，按年份或主题分段获取 PMID、标题、摘要、期刊、作者和医学主题词等元数据。第三步是对文献记录进行 TE 名称匹配和上下文筛选，区分真正讨论目标 TE 的记录、只出现宽泛家族名称的记录和明显无关的误匹配记录。

在候选文献和实体清单形成后，数据流程将进一步抽取 TE 与疾病、功能、基因、蛋白、RNA 或表达上下文之间的候选关系。每条候选关系都应保留来源文献、抽取依据、实体标准化结果和人工审查状态。对于无法确认的关系，系统应保留为待审查记录，而不是直接写入核心图谱。最终输出应包括可导入图数据库的实体表、关系表、文献证据表和失败/跳过记录，使后续更新能够复查每一步数据从何而来、为何被纳入或排除。

4.2 实体标准化与图谱构建

图谱构建首先需要稳定实体边界。TE 名称可能存在家族、亚家族、Rebase、RMSK、DFAM 术语和大小写差异，疾病与功能实体也可能存在同义词。TE-KG 将采用实体标

准化流程，把输入名称解析到规范实体，并保留严格别名与来源信息。对于不能可靠解析的名称，应保留为候选或待审查记录，而不是直接进入核心图谱关系。

在图谱层面，Neo4j 将作为运行时核心。节点类型包括 TE、疾病、功能、基因、蛋白、RNA、药物和论文。关系记录将根据来源实体、目标实体、关系谓词、PMID 支持和来源追踪字段组织。图谱不直接编码“因果强度”，而是编码可被用户检查的关系记录和证据支持。这样可以降低过度解释风险，也便于后续导出和审计。

4.3 文献证据链接

文献证据层将以 PMID 为核心。每条可被文献支持的关系应尽量连接到一个或多个 PMID 记录。PubMed 元数据提供标题、期刊、年份、DOI、医学主题词、关键词、摘要可用性和作者信息，但 PubMed 不提供影响因子 [10]。因此，任何 IF/JCR 信息都必须来自外部期刊指标映射，并在界面和正文中被称为期刊元数据，而不是文章质量或关系可信度。

证据链接将明确区分三类字段。第一类是文献事实字段，如 PMID、标题、年份、期刊和 DOI。第二类是关系支持字段，如 PMID 支持数、证据记录数和覆盖率。第三类是期刊元数据，如 IF 或 JCR 分区。只有前两类可以直接支持“该关系存在文献记录”的陈述；第三类只能辅助用户理解期刊背景，不能参与因果解释。

4.4 表达、基因组与序列上下文

TE 疾病机制研究还需要表达和基因组上下文。TE-KG 将把表达数据运行时作为辅助证据层，使用户能够在查询 TE 实体时查看可用的大规模表达摘要或相关表达视图。序列和基因组位置可作为 TE 身份识别与上下文说明的一部分，用于帮助用户理解某一 TE 家族或亚家族的基本属性。

这一层的边界同样需要明确。表达差异、基因组位置或共识序列不自动证明疾病机制。它们用于帮助研究者提出或筛选假设，并与图谱关系和文献证据共同构成证据包。最终机制解释仍需要人工阅读文献和实验验证。

4.5 用户工作流与导出

用户界面将围绕几个互补入口组织。实体浏览页面用于实体发现和名称确认；路径查找页面用于两个实体之间的连接路径查询；TE-KG 图谱工作区用于可视化邻域浏览、图例筛选和证据表查看；表达页面用于查看 TE 表达上下文；下载页面用于公开文件和导出数据获取。自然语言问答助手将作为面向数据库证据的交互入口，帮助用户把问题转化为可追踪查询，并将不同证据层的结果组织为可阅读回答；但助手输出必须附带来源边界，不能被视为独立科学证据。

导出功能是可复现性的关键。用户应能够导出当前可见子图的节点/边 CSV、关系证据表和图像快照。导出文件需要保留实体 ID、名称、类型、关系类型、PMID 支持和

必要来源追踪信息，使他人可以复查同一查询结果。若某些数据源因许可限制不能公开，系统应提供字段说明、转换脚本和访问路径，而不是公开受限源文件。

4.6 质量控制

质量控制将分为运行时、数据和解释三个层面。运行时层面通过接口契约检查、运行时数据库配置检查、浏览器回归检查和旧数据库回退检查保证关键入口一致。数据层面通过实体标准化、PMID 元数据校验、缺失值保留和日志记录控制错误。解释层面通过命名规范避免过度解释，例如支持字段只能称为证据支持，IF/JCR 只能称为期刊元数据。

5 初步基础

TE-KG 已经具备本地初步平台。系统采用 PHP、浏览器 JavaScript、Neo4j 和 MySQL 的结构，核心页面包括首页、实体浏览、路径查找、TE-KG 图谱工作区、表达查看和下载页面。图谱接口、分类接口和表达接口已形成基本入口。已有检查显示，代表性 TE 名称如 L1HS、AluJb 和 SVA 可以解析，图谱工作区能够加载代表性查询并展示局部图谱。

文献层面，已有记录显示 PubMed 元数据增强流程已产生初步成果，包括唯一 PMID 清单、元数据记录、失败记录和外部期刊指标映射。由于这些数字属于初步平台规模，应谨慎解释：它们可以证明项目有可行基础，但不应被当作最终结果或完整覆盖率。更重要的是，这一基础显示 TE-KG 已经能够把 PubMed 记录和图谱关系连接起来，为目标二提供可执行起点。

前端 workflow 方面，G6 图谱界面已经支持边证据展示、局部图谱浏览和可见子图导出。表达数据运行时使用当前项目的规范数据根目录，避免回退到旧路径。说明页面和下载页面也在整理用户可见说明与公开文件入口。这些已有实现说明该项目不是从零开始，而是在现有初步资源上形成更加严谨、可审查、可公开的研究资源。

6 评估方案

本研究不把当前试运行规模作为最终结果，而是设计一套可执行的评估方案来判断 TE-KG 是否达到资源建设目标。

6.1 覆盖度评估

覆盖度评估将统计 TE 实体、疾病实体、功能实体、关系类型和 PMID 连接关系的数量。对于每一类实体，需要区分原始候选、成功标准化实体和进入核心图谱的实体。

对于关系，需要区分有 PMID 支持的关系、无直接 PMID 的候选关系和仅用于上下文说明的关系。这样可以避免把所有自动抽取结果都视为同等质量的知识。

6.2 证据可追踪性评估

证据可追踪性是 TE-KG 的核心指标。评估时将抽取一组代表性关系，检查用户是否能够从图谱边追踪到 PMID、标题、期刊、年份和其他元数据。每条关系还应检查证据表是否能导出，导出文件是否保留来源追踪字段，以及是否存在 IF/JCR 被误标为可信度的情况。

6.3 代表性案例评估

案例评估将选择 L1HS、AluJb 和 SVA 等代表性 TE。每个案例将围绕三个问题展开：第一，该 TE 的基本分类、序列或基因组上下文是否可找到；第二，该 TE 是否连接到疾病、功能或基因等生物学实体；第三，关键关系是否能够追踪到 PMID 级证据。案例评估不用于证明机制因果性，而用于测试资源是否支持透明探索。

6.4 可复现性与用户 workflow 评估

可复现性评估将检查同一查询在接口、图谱界面和导出文件中是否保持一致。浏览器回归检查、接口契约检查和导出一致性检查可作为技术门禁。用户 workflow 评估则关注研究者是否能够从实体查找进入关系浏览，再进入证据表和导出结果，而不需要理解内部代码结构。

7 预期成果与贡献

该项目的预期成果包括五个层面。第一，构建一个以 TE 为中心、由 Neo4j 支持的知识图谱资源，整合 TE 分类体系、疾病/功能关系、表达上下文和文献证据。第二，形成 PMID 级证据层，使图谱边能够连接到可审查文献记录。第三，提供可浏览、可导出、可复现的用户 workflow，支持研究者从 TE 实体进入局部图谱、路径证据和导出结果。第四，建立面向数据库证据的自然语言问答助手，使用户能够更直接地提出查询、整合证据并识别信息缺口。第五，建立 FAIR 数据开放与质量控制策略，使资源发布时能够清晰说明哪些数据可公开，哪些数据受第三方许可限制。

该资源的主要贡献不是给出某个 TE 疾病机制的最终解释，而是提供一个可审查的信息组织框架。它使研究者能够更快定位候选关系，更清楚地区分证据记录与机制推断，并将图谱查询结果导出用于后续分析或人工审查。对于 TE 研究，这种资源有助于把分散证据组织为可复用、可验证的研究入口。

8 局限性与风险控制

首先，TE-KG 中的关系不等同于因果机制。即使某条 TE-疾病关系有多个 PMID 支持，也只能说明存在文献记录或关联证据，不能自动证明该 TE 导致疾病。本文所有机制性表述都应使用谨慎动词，如“提示”“支持探索”“可能相关”，而不是“证明”或“导致”。

其次，PubMed 元数据不能替代全文阅读。PubMed 提供摘要、题名、医学主题词和文献基本信息，但逐条论断的证据支撑仍需要人工审查原文。TE-KG 可以帮助用户找到相关证据记录，却不能替代文献解读和实验验证。

第三，期刊指标存在解释风险。IF/JCR 属于期刊层面元数据，不是文章质量、关系可信度或因果强度。所有缺失或未匹配的期刊指标应保持为空值、未知或未匹配状态，不应由模型或人工补齐。

第四，数据许可可能限制公开。TE 分类体系、重复序列注释、Rebase、RMSK、DFAM 相关输入和内部影响因子包可能存在再分发限制。因此，资源开放策略必须区分项目生成数据、公开元数据、第三方受限数据和转换脚本。

最后，自然语言问答助手只能作为数据库证据组织工具。它可以帮助用户提出查询、整理证据包或生成报告草稿，但不能作为成熟自治科学发现系统，也不能替代 PMID 级证据审查。

9 数据开放与 FAIR 计划

TE-KG 的数据开放计划将遵循 FAIR 原则。FAIR 是 Findable、Accessible、Interoperable 和 Reusable 的缩写，分别表示数据和元数据应尽可能可发现、可访问、可互操作和可复用 [11]。原则上可公开的内容包括项目源代码、接口契约文档、处理后的图谱导出表、PubMed 衍生元数据、图源数据、检查流程摘要、用户文档和研究方案文档本身。对于可公开的图谱导出，应提供版本号、生成日期、字段说明和来源追踪信息。

受限数据应单独处理。若某些第三方资源或内部指标包不能公开，TE-KG 应公开转换流程、字段定义、缺失值规则和访问说明，而不是重新分发受限源文件。PubMed 衍生元数据的公开也需要遵守 NCBI 使用政策和再分发规范。未来正式发布时，应为每类数据指定仓库位置、许可证和版本标识；在这些信息尚未确定前，本文不应虚构 DOI 或登录号。具体而言，源代码、处理后的图谱导出表、图源数据和用户文档将发布到带版本记录的代码仓库；处理后的 PubMed 衍生元数据将在再分发许可允许的范围内，以 PMID 级来源追踪信息发布；对于第三方或许可受限资源，项目将公开来源说明、转换流程和缺失值规则，除非许可允许，否则不重新分发受限源文件。

10 结论

本文提出构建一个面向转座元件疾病机制研究的证据链接知识图谱资源。该资源以 TE 为中心，把分类体系、疾病/功能关系、表达上下文和 PMID 级文献证据组织到同一可审查工作流中，并通过自然语言问答助手降低用户整合证据的操作门槛。与孤立表格或普通文献检索相比，TE-KG 的目标是提高证据链透明度、导出可复现性和机制假设探索效率。通过谨慎区分证据支持、期刊元数据和生物学解释，并结合 FAIR 数据开放计划，TE-KG 有望成为研究 TE 疾病关系的可复用初步资源和后续论文工作的基础。

参考文献

- [1] International Human Genome Sequencing Consortium. Initial sequencing and analysis of the human genome. *Nature*, 409:860–921, 2001.
- [2] Richard Cordaux and Mark A. Batzer. The impact of retrotransposons on human genome evolution. *Nature Reviews Genetics*, 10:691–703, 2009.
- [3] Edward B. Chuong, Nels C. Elde, and Cedric Feschotte. Regulatory activities of transposable elements: from conflicts to benefits. *Nature Reviews Genetics*, 18:71–86, 2017.
- [4] Guillaume Bourque, Kathleen H. Burns, Mary Gehring, Vera Gorbunova, Andrei Seluanov, Molly Hammell, Michael Imbeault, Zsafia Izsvak, Henry L. Levin, Todd S. Macfarlan, Dixie L. Mager, and Cedric Feschotte. Ten things you should know about transposable elements. *Genome Biology*, 19:199, 2018.
- [5] Kathleen H. Burns. Transposable elements in cancer. *Nature Reviews Cancer*, 17:415–424, 2017.
- [6] Louise M. Payer and Kathleen H. Burns. Transposable elements in human genetic disease. *Nature Reviews Genetics*, 20:760–772, 2019.
- [7] Rui Chen, Christopher A. Ishak, and Daniel D. De Carvalho. Endogenous retroelements and the viral mimicry response in cancer therapy and cellular homeostasis. *Cancer Discovery*, 11:2707–2725, 2021.
- [8] Daniel S. Himmelstein, Antoine Lizée, Christine Hessler, Leo Brueggeman, Sabrina L. Chen, Dexter Hadley, Ari Green, Pouya Khankhanian, and Sergio E. Baranzini. Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726, 2017.
- [9] Payal Chandak, Kexin Huang, and Marinka Zitnik. Building a knowledge graph to enable precision medicine. *Scientific Data*, 10:67, 2023.
- [10] National Library of Medicine. Pubmed overview. <https://pubmed.ncbi.nlm.nih.gov/about/>. Accessed: 2026-06-03.
- [11] Mark D. Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E. Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.