大作业完成程度

以下内容依据《生物学数据库及实验》大作业要求整理，按任务逐条列出，并在每条后说明当前完成情况。

一、项目背景与目标

任务：围绕转座元件（TE），构建知识图谱与智能问答系统

> 已完成。项目主题明确聚焦于转座元件，当前系统以 `LINE-1` 为核心对象，已经完成知识图谱构建、前端展示和智能问答闭环。

任务：综合运用生物信息学、自然语言处理、图数据库和大模型技术

> 已完成。项目中实际使用了文献抓取、摘要信息抽取、Neo4j 图数据库、前端知识图谱可视化，以及基于本地图数据库和大模型的问答模块。

二、核心数据与处理流程

任务：批量获取与转座元件相关的文献摘要和元数据

> 已完成。当前系统基于 PubMed 获取与 `LINE-1` 相关的文献，保留了 `PMID` 、标题和摘要等元数据。

任务：从文本中识别转座元件、疾病、生物学过程/功能、表型等实体

> 已基本完成。当前已构建的知识图谱节点主要包括 `TE` 、 `Disease` 、 `Function` 、 `Paper` ，对应的实体识别流程已经跑通。

任务：提取实体之间的关系

> 已基本完成。当前系统已构建 `BIO_RELATION` 、 `SUBFAMILY_OF` 、 `EVIDENCE_RELATION` 等关系，并能支撑图谱展示和问答检索。

三、系统功能模块

1. 文献挖掘与信息抽取模块

任务：从 PubMed 抓取转座元件相关文献

> 已完成。队友已完成文献抓取脚本和原始数据整理。

任务：利用传统文本挖掘、深度学习模型或大模型 API 进行实体识别和关系抽取

> 已完成基础版本。当前已生成结构化抽取结果，并用于后续图数据库构建。

任务：输出三元组或结构化结果

> 已完成。当前已有 JSONL/CSV 形式的抽取输出，并已转化为 Neo4j 可导入数据。

2. 图数据库搭建模块

任务：将抽取结果结构化并导入图数据库

> 已完成。已使用 Neo4j 构建知识图谱，并完成节点和关系的导入。

任务：设计节点标签与关系类型

> 已完成。当前主要节点包括 `TE` 、 `Disease` 、 `Function` 、 `Paper` ；主要关系包括 `SUBFAMILY_OF` 、 `BIO_RELATION` 、 `EVIDENCE_RELATION` 。

任务：保留文献溯源信息，例如 PMID

> 已完成。文献节点和证据关系中均保留了 `PMID` 相关信息。

3. 知识图谱可视化展示模块

任务：提供 Web 界面，按网络图展示知识节点及其关系

> 已完成。前端页面已支持知识图谱展示、节点交互和搜索。

任务：支持节点拖拽、缩放、点击展开相邻节点

> 已完成。前端已支持拖拽、缩放、聚焦、点击节点和点击关系等交互。

任务：点击连线可显示原始文献摘要及链接信息

> 已部分完成。当前已支持文献证据节点和关系展示，能够体现关系有文献支撑；若要进一步增强为更完整的原始摘要弹窗，后续仍可继续扩展。

4. 基于大模型的智能问答系统

任务：提供类似 ChatGPT 的对话框，支持自然语言提问

> 已完成。网页右侧已集成问答区，可用自然语言提问。

任务：系统结合本地图数据库知识进行回答，并附带参考文献

> 已完成。当前问答模块采用本地图数据库检索与大模型生成结合的方式，并输出参考文献。

任务：采用 RAG 架构，包括 Text2Cypher、知识检索和增强生成

> 已基本完成。当前系统采用了检索增强生成思路，优先进行本地知识检索，再交由大模型组织回答；在实现上采用了更稳妥的模板优先策略，而非完全自由 Cypher 生成。

四、提交材料

任务：提交项目源代码

> 已完成。当前项目已包含爬虫脚本、抽取脚本、Neo4j 导入脚本、前端页面、后端接口和智能问答相关代码。

任务：提交实验报告（Word/PDF）

> 已基本完成框架。LaTeX 报告模板、章节结构、数据规模表、成员分工表、截图占位和模块说明已经准备好；剩余工作主要是补充最终文字、截图和少量评估结果。

任务：实验报告中需包括文本挖掘策略与准确率评估

> 已部分完成。文本挖掘流程已明确，准确率评估方案已整理，但最终抽样结果仍需结合队友材料补全。

任务：实验报告中需包括图数据库 Schema 设计

> 已完成。Schema 设计、节点与关系定义、数据规模统计等内容已写入报告。

任务：实验报告中需包括智能问答系统（RAG）的架构图和 Prompt 设计思路

> 已完成。RAG 架构图已制作，模块四的设计思路和实现逻辑已整理进报告。

任务：实验报告中需包括网站主要功能截图与小组成员分工

> 已基本完成。主要截图已准备，成员分工已整理为三线表形式。

任务：准备答辩 PPT，并进行 5-8 分钟现场演示

> 已在准备阶段。当前已整理展示顺序、原理讲解和答辩问答材料，后续只需据此制作 PPT 并按顺序演示。

五、目前仍需补充或收尾的内容

任务：补齐准确率评估的最终数字

> 尚待补充。需要结合抽样文献和人工核查结果，形成实体识别和关系抽取的准确率表述。

任务：补齐最终实验报告中的少量事实性信息

> 尚待补充。包括个别截图替换、最终成员分工确认、少量文本润色和最终导出 PDF。

任务：准备最终 PPT

> 尚待完成。系统展示材料和讲解材料已经具备，但 PPT 仍需正式制作。