答辩问答

一、项目定位类问题

1. 你们这个项目在做什么？

可以回答：

本项目围绕转座元件，特别是 `LINE-1` ，构建了一个从文献挖掘、知识抽取、图数据库建模、知识图谱可视化到智能问答的完整系统。系统能够将文献中的转座子、疾病、功能和文献证据组织为图结构，并支持自然语言问答。

2. 为什么要做这个项目？

可以回答：

转座元件与基因组演化、基因表达调控以及多种疾病密切相关。相关研究文献很多，如果只靠传统检索，难以快速获得结构化知识。因此我们希望通过知识图谱和智能问答的方式，提高知识组织和检索效率。

3. 你们这个项目的创新点是什么？

可以回答：

本项目的主要创新点在于实现了从文献抓取、摘要信息抽取、Neo4j 图数据库构建、前端图谱展示到基于本地知识库的智能问答闭环；同时，系统支持关系回溯到具体文献证据，而不是只给出没有来源的自然语言回答。

二、文献挖掘与抽取类问题

4. 文献数据是怎么来的？

可以回答：

文献数据来自 PubMed。我们通过自动化脚本检索与 `LINE-1` 相关的文献，获取摘要及其元数据，包括 `PMID` 、标题和摘要文本。

5. 你们如何从文献中提取知识？

可以回答：

我们对摘要进行实体识别和关系抽取。抽取对象包括转座元件名称、疾病名称、生物学功能/机制和文献本身。抽取结果进一步转化为节点与关系，用于后续图数据库建模。

6. 文献抽取结果为什么需要去重和规范化？

可以回答：

因为文献中同一个概念可能有不同写法，例如中英文差异、连字符差异、空格差异、全称与简称差异。如果不做规范化，就会在知识图谱中形成大量重复节点，影响查询和展示效果。

7. 你们怎么做去重？

可以回答：

我们采用了安全去重策略。对明显同义、仅写法不同的节点进行归一化，例如 `LINE1` 与 `LINE-1` 统一，部分疾病名和功能名也统一到标准形式；但对语义接近而不完全等价的项保持保守，不随意合并。

8. 准确率是怎么评估的？

可以回答：

我们采用人工抽样评估。随机抽取一定数量的摘要，对实体识别和关系抽取结果分别进行人工核查，统计正确项和错误项，并总结常见误差来源，例如命名粒度不统一、关系强度不完全准确等。

三、图数据库与知识图谱类问题

9. 为什么用 Neo4j，而不是 MySQL？

可以回答：

因为本项目的核心是实体之间的复杂关系，而不是单纯的二维表数据。Neo4j 更适合表达转座子、疾病、功能、文献之间的关联结构，也更适合后续做路径查询、邻域展开和图谱可视化。

10. 你们的图数据库里有哪些节点?

可以回答:

当前主要包括四类核心节点:

- `TE`
- `Disease`
- `Function`
- `Paper`

其中 `TE` 用于表示转座元件， `Disease` 表示疾病， `Function` 表示机制或功能， `Paper` 表示文献证据。

11. 你们的关系类型有哪些?

可以回答:

主要关系类型包括:

- `SUBFAMILY_OF`
- `BIO_RELATION`
- `EVIDENCE_RELATION`

其中 `SUBFAMILY_OF` 用来表示亚家族与 `LINE-1` 的谱系关系， `BIO_RELATION` 表示转座子与疾病或功能之间的生物学关系， `EVIDENCE_RELATION` 表示文献证据对节点或关联的支撑。

12. 什么是亚家族关系?

可以回答:

`L1HS` 、 `L1PA2` 、 `L1PB1` 等不是和 `LINE-1` 平级的随机节点，而是 `LINE-1` 的亚家族。它们之间通过 `SUBFAMILY_OF` 关系连接，表示谱系从属结构。

13. 为什么你们前端有时候不是把所有节点都展示出来?

可以回答:

因为全量图谱在前端会非常密集，交互成本高，也容易卡顿。当前前端采用的是动态子图展示策略，即根据搜索词或点击节点，只展示与当前主题最相关的一部分节点和关系，以保证可读性和交互性能。

四、前端展示类问题

14. 前端为什么要做聚焦和虚化?

可以回答:

知识图谱节点较多，如果所有节点始终同等显示，用户很难看清中心结构。因此我们在交互层加入了聚焦、弱化和局部高亮，使中心节点、相关节点和无关节点形成清晰的视觉层次。

15. 为什么文献节点放在外围?

可以回答:

文献节点标题较长、数量也较多，如果放在图中心，容易遮挡核心知识节点。因此在布局上尽量将文献节点推向外围，使图中心优先展示转座子、疾病和功能之间的核心结构。

16. 为什么搜索疾病时只展示相关节点，而不是整张图?

可以回答:

因为用户搜索某个疾病时，最关心的是与该疾病直接相关的转座子、机制和支持文献。展示相关子图比展示整张大图更有信息密度，也更适合现场交互演示。

五、智能问答类问题

17. 智能问答模块是怎么工作的?

可以回答:

智能问答模块采用检索增强生成思路。用户提出问题后，系统先从本地 Neo4j 图数据库中检索相关节点、关系和文献，再将这些结构化知识作为上下文交给大模型生成回答，并附带参考文献。

18. 为什么不是直接让大模型随便回答?

可以回答:

如果完全自由生成，容易出现幻觉和无法追溯来源的问题。我们要求问答基于本地图数据库和文献证据，因此采用“先检索、再生成”的方式，以提高可信度和可解释性。

19. 什么是 RAG?

可以回答：

RAG 即 `Retrieval-Augmented Generation` ，也就是检索增强生成。它的核心是先从知识库检索相关事实，再将检索结果提供给大模型生成答案。

20. 你们有没有做 Text2Cypher?

可以回答：

我们参考了 Text2Cypher 的思路，但在实现上采用了更稳妥的策略：优先使用模板化查询，再将检索结果交给大模型组织语言。这样更适合课程项目，稳定性更高。

21. 为什么要有“简单模式”和“详细模式”?

可以回答：

简单模式适合现场快速展示，重点突出、长度较短；详细模式适合展示系统的知识组织能力和检索深度，会提供更完整的机制解释和更多文献支撑。

22. 智能问答的参考文献为什么重要?

可以回答：

因为本项目不是普通聊天机器人，而是知识图谱问答系统。回答需要能够追溯到具体文献证据，否则用户无法判断结论的可信度。

六、系统不足与扩展类问题

23. 你们系统目前还有哪些不足?

可以回答：

当前系统仍有一些可以继续改进的地方，例如命名规范化还可以进一步加强，文献抽取结果中仍可能有少量噪声，前端在全量图谱场景下仍需要更精细的筛选与布局策略，问答模板也可以继续扩展。

24. 如果继续做下去，下一步想做什么？

可以回答：

后续可以扩展到更多转座元件家族，而不只局限于 `LINE-1`；同时可以继续完善疾病、功能、文献之间的规范化映射，增强前端的动态筛选能力，并扩展问答系统对更复杂问题的支持。

25. 你们最终完成了什么？

可以回答：

我们已经完成了从文献抓取、信息抽取、Neo4j 图数据库构建、知识图谱可视化到智能问答的基本闭环，实现了一个可演示、可交互、可回溯文献证据的转座元件知识系统。

七、如果老师追问时，可以用的短句

关于数据库

- 我们的数据核心是关系，所以采用图数据库而不是单纯表结构。
- Neo4j 更适合做邻域展开和路径查询。

关于文献

- 文献是原始证据层，`PMID` 是文献节点的核心唯一标识。
- 我们保留文献节点，是为了支持证据回溯。

关于图谱

- 图谱中的核心节点是 `TE`、`Disease`、`Function` 和 `Paper`。
- 图谱不仅表达“相关”，也表达“谱系关系”和“证据关系”。

关于问答

- 问答不是空泛生成，而是结合本地图数据库检索结果进行生成。
- 参考文献是问答可信度的重要组成部分。