项目概述

1. 数据库名称

本项目的核心数据库为 **Neo4j 图数据库**，当前使用的数据库名称为：

- `tekg`

该数据库主要用于存储转座元件、疾病、生物学功能以及文献证据之间的图结构关系。

2. 总体思路

本项目围绕转座元件，尤其是 `LINE-1`，构建一个从文献到知识图谱再到智能问答的完整系统。总体思路如下：

1. 从 PubMed 获取与 `LINE-1` 相关的文献摘要和元数据
2. 对摘要进行实体识别与关系抽取
3. 对抽取结果进行清洗、规范化和去重
4. 将结构化结果导入 Neo4j 图数据库
5. 在前端页面中以知识图谱形式进行可视化展示
6. 基于本地图数据库检索结果和大模型，实现自然语言问答

整个系统实现了“文献挖掘—知识建图—前端展示—智能问答”的闭环。

3. 数据来源

本项目的数据主要来源于 **PubMed** 文献数据库。

当前数据获取和处理流程包括：

- 使用自动化脚本检索与 `LINE-1` 相关的文献
- 获取每篇文献的：
  - `PMID`

    - 标题（Title）
    - 摘要（Abstract）
- 对文献摘要进行结构化抽取，得到：
    - 转座元件实体
    - 疾病实体
    - 生物学功能/机制实体
    - 文献证据关系

原始文献数据和抽取结果进一步整理后，作为图数据库构建的基础数据源。

4. 数据库表设计

虽然本项目使用的是图数据库 Neo4j，而不是关系型数据库中的传统二维表，但仍然需要进行结构设计。其核心设计可以理解为“节点设计”和“关系设计”。

从原理上看，图数据库和传统表结构数据库的区别在于：

- 关系型数据库强调“行”和“列”
- 图数据库强调“实体”和“实体之间的关系”

本项目的数据重点不是某个对象有多少字段，而是：

- 某个转座元件和哪些疾病有关
- 某个疾病通过哪些机制与转座元件相关
- 某篇文献支持哪一条关系
- 某个亚家族是否属于 `LINE-1` 谱系

因此，这个项目更适合用图结构来组织数据。

4.1 节点设计

数据库中主要包含以下几类节点：

- `TE`
    - 表示转座元件，例如 `LINE-1` 、 `L1HS`
- `Disease`
    - 表示疾病，例如 `阿尔茨海默病`
- `Function`
    - 表示生物学过程、机制或功能，例如 `逆转录转座`

- `Paper`
  - 表示文献节点，包含 `PMID` 、标题等信息

可以把节点理解为知识图谱中的“实体对象”。
例如：

- `(:TE {name: "LINE-1"})`
- `(:TE {name: "L1HS"})`
- `(:Disease {name: "阿尔茨海默病"})`
- `(:Function {name: "逆转录转座"})`
- `(:Paper {pmid: "41767206"})`

这些节点分别代表：

- 一个转座元件家族
- 一个转座元件亚家族
- 一个疾病
- 一个机制/功能
- 一篇具体文献

4.2 关系设计

数据库中主要包含以下关系类型：

- `SUBFAMILY_OF`
  - 表示亚家族与总家族之间的谱系关系
  - 例如： `L1HS -> LINE-1`
- `BIO_RELATION`
  - 表示转座元件与疾病或功能之间的生物学关系
  - 例如： `LINE-1 -> 促进 -> 某疾病`
- `EVIDENCE_RELATION`
  - 表示文献证据与实体之间的支撑关系
  - 用于追溯知识来源

可以把关系理解为实体之间的连接方式。
例如：

- `L1HS -[:SUBFAMILY_OF]-> LINE-1`
- `LINE-1 -[:BIO_RELATION {predicate: "促进"}]-> 乳腺癌`
- `LINE-1 -[:BIO_RELATION {predicate: "参与"}]-> 逆转录转座`
- `某篇文献 -[:EVIDENCE_RELATION {predicate: "报道"}]-> LINE-1`

也就是说，节点负责回答“这是什么”，关系负责回答“它和谁有什么联系”。

其中：

- `SUBFAMILY_OF` 主要描述分类和谱系结构
- `BIO_RELATION` 主要描述转座元件与疾病、功能之间的生物学关联
- `EVIDENCE_RELATION` 主要描述文献证据与知识节点之间的支撑关系

4.3 关键属性

常用属性包括：

- 节点属性：
  - `name`
  - `pmid`
  - `description`
- 关系属性：
  - `predicate`
  - `pmids`
  - `source`

这种设计能够较好支持知识检索、图谱展示和问答生成。

属性的作用是进一步补充节点和关系的细节信息。
例如：

- 节点 `LINE-1` 可以有 `name = "LINE-1"`
- 文献节点可以有 `pmid = "41767206"` 和标题信息
- `BIO_RELATION` 可以用 `predicate` 区分是“促进”“参与”“相关”
- `EVIDENCE_RELATION` 可以用 `pmids` 或文献节点信息来追溯来源

这种设计比为每一种关系单独创建一个完全不同的数据表更灵活，也更适合后续图查询。

4.4 一个完整例子

以 `LINE-1` 与疾病和文献证据的关系为例，知识图谱中可以表示为：

- `L1HS -[:SUBFAMILY_OF]-> LINE-1`
- `LINE-1 -[:BIO_RELATION {predicate: "参与"}]-> 逆转录转座`
- `LINE-1 -[:BIO_RELATION {predicate: "相关"}]-> 阿尔茨海默病`
- `Paper(PMID=41767206) -[:EVIDENCE_RELATION {predicate: "支持关联"}]-> 阿尔茨海默病`

- `Paper(PMID=41767206) -[:EVIDENCE_RELATION {predicate: "报道"}]-> LINE-1`

这意味着系统不仅知道：

- `LINE-1` 和某疾病有关

还知道：

- 它属于什么谱系结构
- 可能涉及什么机制
- 哪篇文献支持这一知识关系

这也是图数据库设计相对传统二维表更适合本项目的原因。

5. 分析、展示内容

当前系统主要支持以下内容的分析与展示：

5.1 转座元件谱系关系展示

可以展示 `LINE-1` 及其亚家族之间的关系，例如：

- `L1HS`
- `L1PA2`
- `L1PB1`
- `L1MA1`

这些亚家族通过 `SUBFAMILY_OF` 关系连接到 `LINE-1` 。

5.2 转座元件与疾病的关联展示

系统可以展示 `LINE-1` 与疾病之间的关联关系，例如：

- 阿尔茨海默病
- 亨廷顿病
- 乳腺癌
- 其他神经系统疾病和肿瘤相关疾病

5.3 转座元件与机制/功能的展示

系统可以展示 `LINE-1` 相关的机制节点，例如：

- 逆转录转座
- 3'端转导
- 插入突变
- DNA 损伤相关过程

5.4 文献证据展示

系统支持文献节点展示与文献回溯，例如：

- 某篇文献支持 `LINE-1` 与某疾病的关系
- 某篇文献报道了某个功能机制

5.5 智能问答展示

系统可围绕图数据库进行问答，例如：

- `LINE-1` 相关疾病
- `LINE-1` 相关功能
- `L1HS` 和 `LINE-1` 是什么关系

6. 前端实现

前端主要负责知识图谱可视化展示与问答交互。

6.1 图谱展示

前端页面基于图谱组件实现网络结构展示，支持：

- 节点与关系可视化
- 搜索节点
- 点击节点和关系查看局部信息
- 聚焦高亮与视觉弱化
- 文献节点、疾病节点、功能节点的颜色区分

6.2 动态检索

前端不仅能加载初始演示图，还可以通过后端接口动态获取图数据库中的相关子图。
例如搜索某个疾病时，前端会向后端发送请求，再由后端到 Neo4j 检索相关节点和关系，并返回给前端展示。

6.3 智能问答交互

前端集成了问答区域，支持：

- 用户输入自然语言问题
- 简单模式与详细模式切换
- 展示基于本地图数据库和文献证据生成的回答

6.4 中英文展示切换

前端支持展示层语言切换，用于在中文和英文模式下以不同方式展示知识图谱和问答结果。

总结

本项目以 `LINE-1` 为核心对象，完成了文献数据获取、知识抽取、图数据库构建、前端图谱展示与智能问答模块的开发，形成了一个较完整的转座元件知识图谱系统。