原理讲解

一、项目整体在做什么

这个大作业的目标，是围绕 **转座元件（Transposable Elements, TE）**，构建一个从文献到知识图谱再到智能问答的完整系统。

系统的整体链路是：

1. 从 PubMed 获取和 `LINE-1` 相关的文献
2. 对文献摘要进行实体和关系抽取
3. 对抽取结果进行清洗、去重和规范化
4. 将结构化知识导入 Neo4j 图数据库
5. 在网页中可视化展示知识图谱
6. 基于本地图数据库和大模型，提供自然语言问答

这个项目不是单纯做网页，也不是单纯做数据库，而是在做一个 **生物信息学知识系统**。

二、什么是转座元件（TE）

1. 定义

转座元件是能够在基因组内部发生位置转移的 DNA 序列。
它们是基因组中的可移动遗传成分。

2. 两大类

Class I：逆转录转座子

这一类通过 RNA 中间体进行转移。
基本过程是：

1. DNA 被转录为 RNA
2. RNA 再逆转录为 DNA
3. 新 DNA 插入到新的基因组位置

它们通常会导致拷贝数增加。

常见类型：

- `LTR retrotransposons`
- `LINE`
- `SINE`

Class II：DNA 转座子

这一类通常不经过 RNA 中间体，主要以 DNA 形式移动。
典型机制是转座酶识别末端序列后切除并重新插入。

3. 为什么这个项目重点做 LINE-1

`LINE-1` 是人类基因组中最重要的一类自主型逆转录转座子。
它在疾病、基因组不稳定性、神经系统病理和肿瘤中都很常见，因此适合作为知识图谱的核心对象。

三、什么是 LINE-1，什么是亚家族

1. 什么是 LINE-1

`LINE-1` 全称为 `Long Interspersed Nuclear Element-1` 。
它不是单一一条序列，而是一个较大的转座子家族。

2. 什么是亚家族

在同一个转座子家族内部，可以按照序列差异、进化时间和系统发育关系，再划分出多个亚家族。

例如：

- `L1HS`
- `L1PA2`
- `L1PA3`
- `L1PB1`
- `L1MA1`

这些都属于 `LINE-1` 谱系中的不同亚家族。

3. 亚家族与 LINE-1 的关系

它们之间最自然的关系是 **分类/谱系关系**，不是功能关系。

例如：

- `L1HS -[:SUBFAMILY_OF]-> LINE-1`
- `L1PA2 -[:SUBFAMILY_OF]-> LINE-1`

这表示：

- `L1HS` 是 `LINE-1` 的亚家族
- `L1PA2` 是 `LINE-1` 的亚家族

这类关系描述的是“属于哪个谱系”，不是“促进什么疾病”。

四、TE 在生物学上的意义

1. 对基因组演化的作用

- 增加基因组大小
- 促进重组与结构变异
- 提供新的调控序列来源
- 促进基因和调控网络演化

2. 对疾病和调控的作用

- 影响基因表达
- 影响染色质状态
- 与肿瘤、神经退行性疾病、神经发育障碍相关
- 与插入突变和基因组不稳定相关

所以，这个项目不是在做一个普通的“文献数据库”，而是在整理一个具有明确生物学意义的知识网络。

五、为什么要用知识图谱，而不是只做表格数据库

1. 关系型数据库擅长什么

MySQL 这类关系型数据库擅长存：

- 用户表
- 课程表
- 商品表
- 订单表

这类数据结构稳定，字段清楚。

2. 你们项目的数据特点

你们的数据重点不是“某个对象有多少列”，而是“对象之间如何连接”。

例如：

- `LINE-1` 与哪些疾病相关
- `LINE-1` 通过哪些机制参与疾病
- 哪篇文献支持这条关系
- `L1HS` 与 `LINE-1` 是什么关系

这种数据天然更适合图数据库。

3. 图数据库的优势

图数据库用：

- 节点（Node）
- 关系（Relationship）
- 属性（Property）

来组织数据，更适合表达复杂连接。

六、什么是 Neo4j

Neo4j 是一种图数据库。

1. 三个核心概念

节点（Node）

表示实体，例如：

- LINE-1
- L1HS
- 阿尔茨海默病
- 逆转录转座
- 某篇文献

关系（Relationship）

表示节点之间的连接，例如：

- SUBFAMILY_OF
- BIO_RELATION
- EVIDENCE_RELATION

属性（Property）

表示附加信息，例如：

- name
- pmid
- predicate
- description

2. 你们项目里的典型节点

- TE
- Disease
- Function
- Paper

3. 你们项目里的典型关系

- SUBFAMILY_OF
- BIO_RELATION
- EVIDENCE_RELATION

七、什么是 Cypher

Cypher 是 Neo4j 的查询语言，相当于图数据库里的 SQL。

1. 基本写法

例如：

```
MATCH (a:TE)-[r:SUBFAMILY_OF]->(b:TE {name: 'LINE-1'})
RETURN a, r, b
```

含义是：

- 找到所有指向 `LINE-1` 的亚家族关系
- 返回节点和边

2. 为什么 Cypher 很重要

因为你们后面做：

- 数据验证
- 图谱展示
- 智能问答

本质上都离不开 Cypher 查询。

八、你们项目里的数据库 Schema 是什么

Schema 可以理解为“数据结构规范”。

它要规定：

- 有哪些节点类型
- 有哪些关系类型
- 每类对象有哪些字段
- 唯一键是什么

1. 节点类型

你们项目中主要有：

- `TE`
- `Disease`
- `Function`
- `Paper`

2. 关系类型

`SUBFAMILY_OF`

表示谱系从属关系，例如：

- `L1HS -> LINE-1`

`BIO_RELATION`

表示生物学关系，例如：

- `LINE-1 -> 促进 -> 癌症`
- `LINE-1 -> 参与 -> 逆转录转座`

这里具体语义存在关系属性 `predicate` 中。

`EVIDENCE_RELATION`

表示文献证据关系，例如：

- `Paper -> 报道 -> LINE-1`
- `Paper -> 支持关联 -> 阿尔茨海默病`

3. 为什么不用很多不同关系名

因为原始抽取结果里的谓词很多、很乱。
如果每个谓词都直接变成一种关系类型，会导致数据库结构混乱。

所以项目里采用了：

- 固定关系类型
- 用属性记录具体语义

这种方式更稳。

九、什么是“去重”和“规范化”

这是这个项目非常关键的一环。

1. 为什么需要去重

文献抽取结果中，常常会出现：

- 同一个实体有不同写法
- 同一个概念有中英文混合写法
- 同义项被抽成多个节点

例如：

- `LINE1`
- `LINE-1`
- `L1`

又例如：

- `3' 转导`
- `3'转导`
- `3'端转导`

如果不去重，图谱就会出现大量重复节点，展示会很混乱。

2. 规范化在做什么

规范化的目标是：

- 把明显同义的项合并成一个标准写法
- 保证数据库内同一个概念只保留一个主节点

3. 去重不能乱做

去重只能合并“明显同义”的项。
如果把并不完全等价的概念强行合并，会造成生物学意义错误。

所以项目里采用的是 **安全去重**：

- 先合并写法差异明显但语义一致的节点
- 对语义相近但不完全相同的项保持保守

十、文献为什么会丢，后来又是怎么查出来的

这个问题你之前问过很多次，它其实非常重要。

1. 原始文献数

最原始的文献数据来自：

- `LINE1_pubmed_data.csv`

2. 抽取输出

抽取后的结构化结果在：

- `output.jsonl`

3. 为什么后来发现文献减少

因为最早建图时， `Paper` 节点不是按照每条 `PMID` 文献记录创建的，而是按照抽取结果中的 `entities.papers` 创建的。

这会带来两个问题：

- 某篇文献如果没有被抽成 `paper` 实体，就会直接丢失
- 如果按标题而不是 `PMID` 去重，不同文献可能会被错误合并

4. 后来怎么修

后来的修正逻辑是：

- `Paper` 节点必须以原始文献记录为基础
- 唯一键优先使用 `PMID`
- 即使某篇文献没有抽出强关系，也不应当从数据库中消失

这是一个非常重要的工程原则：

> 文献是原始证据，不应仅依赖抽取结果决定它是否存在。

十一、为什么前端曾经会“搜不到”或者“只显示两个点”

1. 早期前端的问题

最开始前端使用的是：

- 一个静态的 `graph_demo_data.js`

这个文件只包含一个演示子图，不是完整数据库。

所以：

- 搜不到某个疾病
- 搜到了但只有少量节点

都是可能发生的。

2. 后来为什么改成动态查询

因为如果前端只用静态子图，就无法体现完整知识图谱。

所以后来增加了：

- `api/graph.php`

由后端去 Neo4j 动态查询相关子图，再返回给前端。

3. 为什么又会卡死

如果后端一次返回太大的两层子图，前端布局计算会非常慢，页面会卡住。

所以后来又做了显示层控制：

- 保留核心相关节点
- 避免一次性把几百上千个元素全塞进前端

这不是丢数据，而是 **为了前端可视化可用性做展示层裁剪**。

十二、为什么黄色文献节点要放在外围

黄色节点代表文献。

如果文献节点混在图中心，会产生两个问题：

1. 文献标题长，容易挡住别的节点
2. 文献数量一多，图中心会非常拥挤

所以后来前端布局做了一个策略：

- 尽量把 `Paper` 节点推到外圈
- 把 `TE / Disease / Function` 放在更核心的位置

这样做的原因是：

- 核心知识关系更容易看清
- 文献仍然存在，但不会挡住中心结构

十三、什么是“聚焦程度”

聚焦程度是前端交互里的一个参数，用来控制：

- 搜索或点击某节点时，视图放大多少
- 中心节点和周围节点之间的视觉差异有多明显

1. 为什么需要聚焦

因为如果整个图一开始全部展示，信息量太大，很难看清局部关系。

2. 聚焦不等于删数据

聚焦只是：

- 改变当前视图范围
- 突出局部节点和边
- 弱化无关节点

它本质上是显示层处理，不是数据库删数据。

3. 你们后来对聚焦做了什么优化

- 中心节点最亮
- 相连节点轻度虚化
- 无关节点中度虚化
- 点击边时只突出边和端点

这些优化的目标都是：

> 让局部关系更容易看清，同时不至于误删信息。

十四、为什么要有“简单模式”和“详细模式”

智能问答模块不是只有“能答”和“不能答”两种状态。

展示时有不同需求：

简单模式

适合：

- 答辩现场快速展示
- 几句话说明结论
- 控制字数

特点：

- 结构紧凑
- 重点突出
- 文献数量较少

详细模式

适合：

- 展示系统深度
- 展示检索和生成能力
- 输出更接近学术化说明

特点：

- 描述更完整
- 机制展开更多
- 参考文献更丰富

这两种模式不是两个完全不同系统，而是：

> 同一条问答链路，在输出层对信息密度和表达长度做了不同控制。

十五、什么是模块四：基于大模型的智能问答系统

这是这个大作业最核心的创新模块之一。

1. 功能目标

用户可以用自然语言提问，例如：

- `LINE-1 相关疾病`
- `LINE-1 相关功能`
- `L1HS 和 LINE-1 是什么关系`

系统要基于本地图数据库返回答案，并附带参考文献。

2. 为什么不能直接让大模型随便回答

如果完全让大模型自由生成，容易出现：

- 幻觉
- 引用不真实
- 和本地数据库脱节

所以项目里采用的是：

> 先检索，再生成

也就是 RAG 思路。

十六、什么是 RAG

RAG 是 `Retrieval-Augmented Generation`，即 **检索增强生成**。

1. 基本流程

1. 用户提出问题
2. 系统识别问题中的核心实体和意图
3. 到本地数据库中检索相关结构化知识
4. 把检索结果整理成上下文
5. 再交给大模型生成回答

2. 你们项目中的 RAG

大致链路是：

1. 前端输入问题
2. PHP 后端接收问题
3. 优先走模板化检索
4. 如果模板不适用，再尝试更灵活的查询逻辑
5. 从 Neo4j 获取节点、关系、文献
6. 将结构化结果交给 Qwen
7. 返回带参考文献的答案

3. 为什么这种方式更合理

因为它能做到：

- 回答依赖本地知识库
- 文献可追溯
- 幻觉风险更低
- 更符合课程作业要求

十七、为什么不一开始就完全自由 Text2Cypher

老师文档里提到了 `Text2Cypher`，即：

- 用户自然语言问题

- 大模型转成 Cypher
- 去 Neo4j 查询

这个思路是对的，但如果直接完全自由生成，会有几个问题：

- Cypher 容易写错
- 谓词和标签不稳定
- 数据库一旦变动就容易失配
- 调试成本高

所以项目里采用了更稳的策略：

1. 模板优先

例如：

- `LINE-1 相关疾病`
- `LINE-1 相关功能`
- `L1HS 有哪些文献证据`

这些可以先用稳定模板完成。

2. 再由模型负责表达层

即：

- 检索结果先查出来
- 再让模型组织语言

这种方式对课程项目更稳。

十八、问答里为什么要附参考文献

因为这个系统不是普通聊天机器人，而是 **知识图谱问答系统**。

如果没有文献证据，用户无法判断：

- 回答是否来自本地知识库
- 回答是否有依据
- 哪篇论文支持这个结论

所以参考文献是必须的。

这也是为什么要在图数据库里保留：

- `Paper` 节点
- `PMID`
- `EVIDENCE_RELATION`

十九、为什么会出现中英文混杂

这是文献型系统常见的问题。

原因包括：

1. 原始文献本来是英文
2. 抽取后有些实体用了英文标准名
3. 前端又希望有中文展示
4. 同时还要考虑用户搜索时可能输入中文别名

所以后来前端做了展示层双语：

- 数据库里尽量保留规范名
- 前端根据模式切换显示中文或英文

这样做比在数据库里强行全改中文更合理。

二十、为什么搜索“阿尔兹海默症”也能找到“阿尔茨海默病”

这依赖于 **别名映射**。

用户搜索时，输入的不一定是数据库里的标准名。
例如：

- 阿尔兹海默症
- 阿尔茨海默病
- `Alzheimer's disease`

本质上都应该指向同一个疾病概念。

所以后端在图谱搜索时做了别名归一化。
这样即使输入不是数据库里的标准写法，也能匹配到正确节点。

二十一、为什么截图里会出现重复节点，这是怎么避免的

重复节点一般来源于：

- 同义项没合并
- 中英写法不同
- 标点和空格差异
- 名词边界不一致

避免它的方法就是：

1. 做规范化映射
2. 做安全去重
3. 重新生成导入文件
4. 重新导入数据库

也就是说，去重不是只改前端显示，而是要从数据管线本身处理。

二十二、你们这个系统最核心的创新点是什么

可以概括成三点：

1. 从文献到知识图谱的闭环

不是手工写死数据，而是：

- 文献抓取
- 信息抽取
- 结构化建图

2. 图数据库 + 可视化 + 问答联动

不是只有图，也不是只有聊天，而是：

- 图数据库负责存储
- 前端负责展示
- 智能问答负责查询与解释

3. 以本地知识库为基础的问答

问答不是空泛生成，而是基于：

- 本地 Neo4j 图数据库
- 文献证据
- 检索增强生成

二十三、如果答辩时老师问“你们系统目前还有什么不足”

可以从这几个方向回答：

1. 命名规范化仍可继续加强
2. 文献抽取结果仍存在少量噪声
3. 前端在全量图谱场景下仍需继续优化布局与筛选
4. 智能问答目前优先支持核心问题模板，未来可扩展到更复杂问题
5. 当前研究对象以 LINE-1 为核心，未来可扩展到更多转座元件家族

这类回答既真实，也不会显得系统很差。

二十四、如果你当天需要快速复习，优先记住这几句

1. 关于数据库

> 我们使用 Neo4j 图数据库来组织转座元件、疾病、功能和文献之间的复杂关系。

2. 关于图谱

> 图谱中的节点表示实体，边表示实体之间的关系，文献节点用于提供证据支持。

3. 关于 LINE-1 亚家族

> `L1HS` 、 `L1PA2` 、 `L1PB1` 等都是 `LINE-1` 的亚家族，它们通过 `SUBFAMILY_OF` 关系连接到 `LINE-1` 。

4. 关于模块四

> 智能问答模块采用检索增强生成思路，先从本地图数据库检索相关结构化知识，再结合大模型生成带参考文献的回答。

5. 关于项目价值

> 本项目实现了从文献挖掘、知识图谱构建、图谱可视化到智能问答的完整闭环。

二十五、最后的理解方式

你可以把整个项目理解为四层：

1. **文献层**
   负责提供原始证据
2. **知识层**
   负责把实体和关系结构化
3. **图数据库层**
   负责组织和检索这些知识
4. **应用层**
   负责可视化展示和智能问答

这个大作业真正完成的，不是某一个零散功能，而是把这四层接起来了。